



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

MODELIZACIÓN DE DATOS CON ESTRUCTURA MIXTA: UN ANÁLISIS DEL CONTEO DE MUERTES EN EUROPA

Juan José Doblas Martínez

Matemáticas

Escola Politècnica Superior

Año académico 2024-25

MODELIZACIÓN DE DATOS CON ESTRUCTURA MIXTA: UN ANÁLISIS DEL CONTEO DE MUERTES EN EUROPA

Juan José Doblas Martínez

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2024-25

Palabras claves del trabajo: regresión binomial negativa, mortalidad, efectos aleatorios y datos composicionales.

Tutores: Irene García y Alirio Cruz

Autorizo a la Universidad a incluir este trabajo en el repositorio institucional para su consulta en acceso abierto y difundirlo en línea, con fines exclusivamente académicos y de investigación.

Autor		Tutores	
Sí	No	Sí	No
☒	☐	☒	☐

A mi familia, pareja y amigos por confiar en mí y apoyarme siempre. Especialmente a
mi madre, por ser mi modelo a seguir.

ÍNDICE GENERAL

Índice general	iii
Acrónimos	v
Resumen	vii
1 Introducción	1
2 Introducción a los modelos lineales generalizados	3
2.1 Modelos lineales	3
2.2 Familia exponencial de distribuciones	5
2.3 Función score	7
2.4 Modelos lineales generalizados	8
2.5 Estimación máximo verosímil	9
2.6 Inferencia	12
2.6.1 Distribución muestral del estadístico score	14
2.6.2 Aproximaciones por series de Taylor	14
2.6.3 Distribución muestral de los estimadores máximo-verosímiles	15
2.6.4 Estadístico de ratio de log-verosimilitud	15
2.6.5 Distribución muestral de la devianza	16
2.6.6 Contrastes de hipótesis	17
3 Adaptación de los modelos lineales generalizados a datos de conteo sobre-dispersos	19
3.1 Distribución Binomial Negativa	20
3.2 Método de scoring aplicado a un vector aleatorio con distribución Binomial Negativa	21
3.3 Cálculo de la devianza	23
3.4 Inclusión de efectos aleatorios, temporales y composicionales	24
3.4.1 Ajuste temporal	25
3.4.2 Ajuste por tamaño: uso del <i>offset</i>	26
3.4.3 Capturar la heterogeneidad entre grupos: efectos mixtos	26
4 Conteo de muertes en Europa	29
4.1 Datos de mortalidad en Europa	29
4.1.1 Descripción del conjunto de datos	30
4.2 Procesamiento de datos para el análisis	31

4.3	Tratamiento de datos composicionales	35
4.3.1	Imputación de ceros	35
4.3.2	Transformación CLR	35
4.4	Matriz de correlaciones	37
4.5	Tendencias temporales	40
4.6	Análisis en componentes principales	44
4.7	Ajuste del Modelo Binomial Negativo con Efectos Mixtos y <i>offset</i>	47
4.7.1	Motivación para usar un modelo Binomial Negativo	47
4.7.2	Descripción del modelo propuesto	48
4.7.3	Estimación del modelo	48
4.7.4	Interpretación del modelo ajustado	51
4.7.5	Análisis de residuales	52
5	Conclusiones	57
A	Apéndices	59
A.1	Análisis de componentes principales	59
A.1.1	ACP 1990	59
A.1.2	ACP 2019	62
A.2	Análisis en coordenadas principales	64
	Bibliografía	69

ACRÓNIMOS

ACP Análisis en Componentes Principales

ALR Additive Log-Ratio

CLR Centered Log-Ratio

DFE Distribución en la Familia Exponencial

GLM Generalized Linear Model

GLMM Generalized Linear Mixed Model

IDH Índice de Desarrollo Humano

ILR Isometric Log-Ratio

LM Linear Model

NB Negative Binomial

NBMM Negative Binomial Mixed Model

OMS Organización Mundial de la Salud

PIB Producto Interior Bruto

RESUMEN

Modelizar una variable de respuesta de conteo, como el número de muertes en Europa, representa un desafío estadístico, ya que estos datos son enteros, no negativos y, con frecuencia, presentan sobredispersión o estructuras de dependencia espacial y temporal. Los modelos lineales generalizados mixtos (GLMM, por sus siglas en inglés) ofrecen una solución flexible al permitir el uso de distribuciones apropiadas para este tipo de datos, como la de Poisson o la binomial negativa e incorporar efectos aleatorios que capturan la variabilidad entre países, regiones o años. Esta capacidad es fundamental al analizar patrones de mortalidad en contextos tan heterogéneos como el europeo, donde los factores demográficos, económicos y sanitarios varían significativamente entre territorios.

En este trabajo abordamos la modelización de conteos de fallecimientos causados por distintas enfermedades entre los años 1990 y 2019. Al tratarse de datos de conteo, comenzamos revisando los fundamentos de los Modelos Lineales Generalizados (GLM) e introducimos el problema de los datos composicionales, caracterizados por ser no negativos, sumar un total constante y presentar relaciones internas entre sus componentes. Si bien el modelo de Poisson es el punto de partida clásico para datos de conteo, la suposición de equidispersión (varianza igual a la media) no se ajusta a la realidad de los datos. Por ello, se justifica el uso de un Modelo Binomial Negativo Mixto (NBMM), que se adapta mejor a su naturaleza.

La base de datos empleada recoge, para cada país y año, el número total de muertes, el número de muertes atribuidas a enfermedades del sistema nervioso, el Índice de Desarrollo Humano (IDH) y otras variables explicativas. Se ajusta un NBMM que incluye como término de ajuste (offset) el logaritmo del total de muertes, así como covariables con términos polinómicos en el tiempo (como t^2 y t^3) y el IDH. Además, se incorpora un efecto aleatorio por país, con el objetivo de capturar la heterogeneidad estructural entre naciones. El ajuste del modelo confirma que el parámetro de sobredispersión es significativamente mayor que cero, lo que valida la presencia de sobredispersión y descarta la idoneidad del modelo de Poisson. Finalmente, el análisis de los residuales de Pearson, estratificados por año, grupo de IDH y país, permite identificar patrones no capturados por el modelo y sugiere posibles mejoras.

En conjunto, el modelo propuesto constituye una herramienta estadística robusta para examinar tendencias y desigualdades en la mortalidad por enfermedades del sistema nervioso en Europa. Podemos concluir que ofrece una base cuantitativa sólida para el análisis comparado entre países y la formulación de políticas de salud pública basadas en evidencia.

CAPÍTULO 1

INTRODUCCIÓN

Los modelos lineales clásicos parten de la suposición de que la variable respuesta es continua, normal y homocedástica. Sin embargo, cuando trabajamos con datos de conteo (enteros no negativos), esta formulación puede generar predicciones fuera de lo posible y violar la naturaleza discreta de la variable.

Para superar estas limitaciones, los Modelos Lineales Generalizados (GLM) extienden la regresión lineal sustituyendo la distribución normal por una perteneciente a una familia más general, relacionando la media con la predicción lineal mediante una función enlace.

No obstante, al aplicar un GLM Binomial Negativo (apto para datos de conteo sobredispersos) surgen nuevas complejidades que abordamos en el Capítulo 3. Primero, en datos composicionales cada conteo debe interpretarse como proporción de un total variable, lo que se resuelve añadiendo un *offset* al predictor lineal. Segundo, para capturar la trayectoria temporal no lineal, incorporamos un polinomio cúbico en el tiempo. Y tercero, para reflejar la heterogeneidad entre países (o unidades), extendemos el GLM a un Modelo Lineal Generalizado Mixto (GLMM), añadiendo efectos aleatorios que permiten variaciones de intercepto según el grupo.

A continuación, la exponemos la estructura de la memoria:

En el primer capítulo explicamos los fundamentos de los GLM: definimos la familia exponencial de distribuciones y vemos sus propiedades, definimos qué es un GLM, exponemos la inferencia por máxima verosimilitud junto con el método Scoring y detallamos las pruebas de ajuste.

En el segundo capítulo desarrollamos el modelo que aplicaremos en el caso práctico: presentamos la regresión de Poisson y motivamos la transición al modelo binomial negativo para resolver la sobredispersión. Desarrollamos el método de scoring específico para esta distribución, calculamos la devianza y explicamos la inclusión de *offset*, polinomio temporal y efectos mixtos.

Por último, en el tercer capítulo nos centramos en la aplicación del modelo a una base de datos: tras un análisis exploratorio de los datos, ajustamos el NBMM a las muertes por enfermedades del sistema nervioso en los países europeos entre 1990

1. INTRODUCCIÓN

y 2019. Validamos el modelo con residuos de Pearson agrupados por año, nivel de desarrollo humano y país.

INTRODUCCIÓN A LOS MODELOS LINEALES GENERALIZADOS

En este primer capítulo presentamos un marco teórico sobre los modelos lineales generalizados (GLM, por sus siglas en inglés), exponiendo sus principios fundamentales y características esenciales. Comenzaremos recordando en qué consiste un modelo lineal (LM), definiremos la familia exponencial de distribuciones y estudiaremos sus propiedades, así como la función score; finalmente abordaremos la definición y características esenciales de los GLM.

2.1 Modelos lineales

Comencemos definiendo qué es un modelo estadístico.

Definición 1. Un **modelo estadístico** es una representación matemática del proceso generador de datos que se basa en una familia de distribuciones de probabilidad. Formalmente, se define como:

$$(\mathcal{X}, \mathcal{A}, \mathcal{P}),$$

donde:

- $\mathcal{X}$ es el espacio muestral, es decir, el conjunto de todos los posibles valores observables.
- $\mathcal{A}$ es una σ -álgebra de eventos sobre $\mathcal{X}$.
- $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ es una colección de medidas de probabilidad en $(\mathcal{X}, \mathcal{A})$ indexadas por un parámetro (o vector de parámetros) θ que toma valores en el espacio paramétrico Θ .

Un ejemplo de un modelo estadístico sería el siguiente modelo lineal gaussiano de regresión múltiple descrito por $(\mathcal{X}, \mathcal{A}, \mathcal{P})$ definido de la siguiente forma:

- **Espacio muestral:** $\mathcal{X} = \mathbb{R}^n$, el conjunto de todos los posibles vectores de observación $\mathbf{y} = (y_1, \dots, y_n)^\top$.
- **σ -álgebra:** $\mathcal{A} = \mathcal{B}(\mathbb{R}^n)$, la σ -álgebra de Borel sobre $\mathbb{R}^n$.
- **Familia de medidas de probabilidad:**

$$\mathcal{P} = \{P_{\boldsymbol{\beta}, \sigma^2} : (\boldsymbol{\beta}, \sigma^2) \in \Theta\},$$

donde el espacio paramétrico es

$$\Theta = \mathbb{R}^p \times (0, +\infty),$$

y bajo cada medida de probabilidad $P_{\boldsymbol{\beta}, \sigma^2}$ la variable aleatoria

$$\mathbf{Y} = (Y_1, \dots, Y_n)^\top$$

sigue una distribución normal multivariante

$$\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

Es decir, para todo $A \in \mathcal{B}(\mathbb{R}^n)$,

$$P_{\boldsymbol{\beta}, \sigma^2}(\mathbf{Y} \in A) = \int_A \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right\} d\mathbf{y}.$$

A continuación, definamos formalmente qué es un modelo lineal.

Definición 2. Un **modelo lineal** es un modelo estadístico que relaciona una **variable respuesta** con un conjunto de **variables explicativas** independientes mediante una combinación lineal, más un término de error aleatorio.

Es decir, sean $\{Y_i\}_{i=1, \dots, n}$ las n variables respuesta y X_{ij} , con $i = 1, \dots, n$ y $j = 1, \dots, p$, las np variables explicativas. Entonces, un modelo lineal es:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \varepsilon_i, \quad (2.1)$$

donde $\beta_0, \beta_1, \dots, \beta_p \in \mathbb{R}$ son parámetros desconocidos, ε_i es una variable aleatoria y las variables explicativas X_{ij} toman valores conocidos. Supondremos que $\varepsilon_i \sim N(0, \sigma^2)$ y por tanto que

$$E[Y_i] = \mu_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}, \quad (2.2)$$

Otra forma de escribir (2.1) y (2.2) es de forma matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.3)$$

$$E[\mathbf{Y}] = \boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}, \quad (2.4)$$

donde $\mathbf{X}$ es una matriz de dimensión $n \times (p+1)$ cuya primera columna ($j=0$) tiene por elementos el 1.

Las formas más usuales de estimar el vector de parámetros $\boldsymbol{\beta}$ es mediante el método de máxima verosimilitud o mínimos cuadrados [1]. En este capítulo veremos el primero.

Definición 3. Sean $y_1, \dots, y_n$ observaciones muestrales tomadas de variables aleatorias correspondientes $Y_1, \dots, Y_n$ cuya distribución depende de un parámetro θ . Entonces, si $Y_1, \dots, Y_n$ son variables aleatorias discretas, la **verosimilitud** de la muestra, $L(\theta; y_1, \dots, y_n)$, se define como la probabilidad conjunta de $y_1, \dots, y_n$. Si $Y_1, \dots, Y_n$ son variables aleatorias continuas, la verosimilitud, $L(\theta; y_1, \dots, y_n)$, se define como la densidad conjunta evaluada en $y_1, \dots, y_n$.

Notemos que la verosimilitud es una función que depende del parámetro θ . En el método de máxima verosimilitud se busca el valor $\hat{\theta}$ que maximiza esta función. Sin embargo, no lo calcularemos directamente sobre esta función, sino sobre el logaritmo con base e , ya que, por ser una función creciente, se tiene

$$\hat{\theta} = \arg\max(L(\theta; \mathbf{y})) = \arg\max(\ln(L(\theta; \mathbf{y})))$$

Definición 4. Sean $y_1, \dots, y_n$ observaciones muestrales tomadas de variables aleatorias correspondientes $Y_1, \dots, Y_n$ cuya distribución depende de un parámetro θ . La **log-verosimilitud** es el logaritmo neperiano de la verosimilitud y la escribiremos como

$$l(\theta; \mathbf{y}) = \ln(L(\theta; \mathbf{y}))$$

2.2 Familia exponencial de distribuciones

Tras haber visto que en los modelos lineales clásicos asumimos

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2),$$

podemos interpretar ese supuesto de normalidad como la elección de una distribución concreta dentro de una clase mucho más amplia: la **familia exponencial**. Esta familia reúne a muchas de las distribuciones que usamos en la práctica y es la base teórica de los GLM.

Definición 5. Sea Y una variable aleatoria cuya distribución de probabilidad depende de un solo parámetro θ . Diremos que la distribución pertenece a la **familia exponencial** si su función de densidad o probabilidad se puede escribir como

$$f(y; \theta) = s(y) t(\theta) e^{a(y)b(\theta)}, \quad (2.5)$$

donde a , b , s y t son funciones conocidas. Si $a(y) = y$ se dice que la distribución está en **forma canónica** y, en tal caso, $b(\theta)$ es llamado el **parámetro natural** de la distribución.

Observemos que (2.5) también se puede escribir como

$$f(y; \theta) = \exp[a(y)b(\theta) + c(\theta) + d(y)], \quad (2.6)$$

con $s(y) = e^{d(y)}$ y $t(\theta) = e^{c(\theta)}$.

Hay algunas distribuciones, p. ej. la distribución normal, que dependen de más de un parámetro. Si esto ocurre, se consideran **parámetros molestos**¹ que forman parte de las funciones a , b , c y d y se tratan como si fueran conocidos.

Distribución	Parámetro natural (b)	c	d
Poisson	$\ln(\lambda)$	$-\lambda$	$-\ln(y!)$
Binomial	$\ln\left(\frac{p}{1-p}\right)$	$n \ln(1-p)$	$\ln\left(\frac{n}{y}\right)$
Binomial Negativa	$\ln(1-p)$	$r \ln(p)$	$\ln\left(\frac{y+r-1}{y}\right)$
Normal	$\frac{\mu}{\sigma^2}$	$-\frac{\mu^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2)$	$-\frac{y^2}{2\sigma^2}$

Cuadro 2.1: Algunas distribuciones conocidas como miembros de la familia exponencial

Veamos algunos ejemplos en la tabla (2.1) de distribuciones conocidas que pertenecen a la familia exponencial en forma canónica:

Observemos que en las distribuciones Binomial, Binomial Negativa y Normal tenemos los parámetros (p, n) , (p, r) y (μ, σ) , respectivamente, donde n , r y σ los tratamos como parámetros molestos.

Proposición 6. Propiedades de las distribuciones en la familia exponencial. Sea Y una variable aleatoria con Distribución en la Familia Exponencial (DFE), es decir, su función de densidad o probabilidad viene dada por

$$f(y; \theta) = \exp[a(y)b(\theta) + c(\theta) + d(y)]$$

Entonces se tiene que:

- i. $E[a(Y)] = -\frac{c'(\theta)}{b'(\theta)}$
- ii. $\text{var}[a(Y)] = \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{(b'(\theta))^3}$

Demostración.

- i. Por definición de función de densidad tenemos que

$$\int_E f(y; \theta) dy = 1, \quad (2.7)$$

siendo E el codominio de la variable aleatoria Y (Si Y es una variable aleatoria discreta, se procede de manera análoga con un sumatorio). Derivando ambos lados respecto de θ y aplicando la regla de Leibniz obtenemos

$$\begin{aligned} 0 &= \int_E \frac{\partial f}{\partial \theta}(y; \theta) dy = \int_E (a(y)b'(\theta) + c'(\theta))f(y; \theta) dy \\ &= b'(\theta) \int_E a(y)f(y; \theta) dy + c'(\theta) \int_E f(y; \theta) dy = b'(\theta)E[a(Y)] + c'(\theta) \end{aligned}$$

de donde se deduce el resultado.

¹parámetros que no son de interés para la inferencia, pero son necesarios para definir la verosimilitud

ii. Derivando (2.7) dos veces respecto de θ obtenemos

$$0 = \int_E \frac{\partial^2 f}{\partial \theta^2}(y; \theta) dy = \int_E (a(y)b''(\theta) + c''(\theta))f(y; \theta) + (a(y)b'(\theta) + c'(\theta))^2 f(y; \theta) dy$$

Teniendo en cuenta que $(a(y)b'(\theta) + c'(\theta))^2 = (b'(\theta))^2(a(y) - E[a(Y)])^2$ y que $\text{var}[a(Y)] = \int_E (a(y) - E[a(Y)])^2 f(y; \theta) dy$ deducimos que

$$0 = b''(\theta)E[a(Y)] + c''(\theta) + (b'(\theta))^2 \text{var}[a(Y)]$$

Con lo que finalmente concluimos que

$$\text{var}[a(Y)] = -\frac{b''(\theta)E[a(Y)] + c''(\theta)}{(b'(\theta))^2} = \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{(b'(\theta))^3}$$

□

2.3 Función score

La función score proporciona una medida de la sensibilidad de la log-verosimilitud frente a variaciones del parámetro canónico. A continuación definiremos formalmente la función score en el contexto de la familia exponencial y estudiaremos sus propiedades principales.

Notemos que la función de log-verosimilitud asociada a una variable aleatoria Y con DFE viene dada por

$$l(\theta; y) = a(y)b(\theta) + c(\theta) + d(y)$$

Definición 7. La **función score** asociada a una variable aleatoria Y con DFE es la derivada respecto del parámetro de la función de log-verosimilitud, es decir,

$$U(\theta; y) = \frac{\partial l}{\partial \theta}(\theta; y) = a(y)b'(\theta) + c'(\theta)$$

Como la función score depende de y también puede ser vista como una variable aleatoria:

$$U = a(Y)b'(\theta) + c'(\theta)$$

Proposición 8. Sea Y una variable aleatoria con DFE. Entonces, para la variable aleatoria $U = a(Y)b'(\theta) + c'(\theta)$ se tiene que

$$E[U] = 0$$

Demostración. Por linealidad de la esperanza y aplicando la proposición 6, tenemos

$$E[U] = b'(\theta)E[a(Y)] + c'(\theta) = b'(\theta) \left(-\frac{c'(\theta)}{b'(\theta)} \right) + c'(\theta) = 0$$

□

Definición 9. La **información** de una variable aleatoria Y con DFE viene dada por $\text{var}[U]$ y se denotará por $\mathfrak{J}$.

Veamos algunas propiedades de la información.

Proposición 10. Sea Y una variable aleatoria con DFE. Entonces, para la variable aleatoria $U = a(Y)b'(\theta) + c'(\theta)$ se tiene que

$$\mathfrak{J} = \text{var}[U] = \frac{b''(\theta)c'(\theta)}{b'(\theta)} - c''(\theta)$$

Demostración. Por propiedades de la varianza y aplicando la proposición 6, tenemos

$$\mathfrak{J} = (b'(\theta))^2 \text{var}[a(Y)] = (b'(\theta))^2 \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{(b'(\theta))^3} = \frac{b''(\theta)c'(\theta)}{b'(\theta)} - c''(\theta)$$

□

Proposición 11. Sea Y una variable aleatoria con DFE. Se cumple que

$$\mathfrak{J} = E[U^2] = -E[U'],$$

siendo $U' = \frac{\partial U}{\partial \theta}$

Demostración. La primera igualdad se obtiene de la expresión de la varianza $\text{var}[U] = E[U^2] - (E[U])^2$, teniendo en cuenta que $E[U] = 0$.

Veamos la segunda igualdad. Derivando U respecto de θ se tiene que

$$U' = \frac{\partial U}{\partial \theta} = a(Y)b''(\theta) + c''(\theta)$$

Entonces, por la proposición 6,

$$-E[U'] = -b''(\theta)E[a(Y)] - c''(\theta) = -b''(\theta) \left(-\frac{c'(\theta)}{b'(\theta)} \right) - c''(\theta) = \frac{b''(\theta)c'(\theta)}{b'(\theta)} - c''(\theta) = \mathfrak{J}$$

□

2.4 Modelos lineales generalizados

Los modelos lineales generalizados nos ofrecen un marco unificado para abordar variables de respuesta que toman valores en un subconjunto restringido de $\mathbb{R}$.

Sean $Y_1, \dots, Y_n$ n variables aleatorias independientes con DFE que cumplen con las siguientes propiedades:

1. Las distribuciones de cada Y_i tienen la forma canónica y dependen de un solo parámetro θ_i (no necesariamente el mismo para cada variable). Así,

$$f(y_i; \theta_i) = \exp[y_i b_i(\theta_i) + c_i(\theta_i) + d_i(y_i)]$$

2. Todas las variables aleatorias Y_i tienen la misma distribución. De esta manera, las funciones b_i , c_i y d_i son iguales y no será necesario el subíndice.

Por lo tanto, la función de densidad (o de probabilidad) conjunta de las variables Y_i es

$$\begin{aligned} f(y_1, \dots, y_n; \theta_1, \dots, \theta_n) &= \prod_{i=1}^n f(y_i; \theta_i) = \prod_{i=1}^n \exp[y_i b(\theta_i) + c(\theta_i) + d(y_i)] \\ &= \exp \left[\sum_{i=1}^n y_i b(\theta_i) + \sum_{i=1}^n c(\theta_i) + \sum_{i=1}^n d(y_i) \right] \end{aligned}$$

Como puede haber un parámetro θ_i por cada observación, estos no serán de interés de forma directa. Normalmente nos centraremos en un conjunto mucho más pequeño de parámetros $\beta_0, \beta_1, \dots, \beta_p$ (con $p \ll n$). Sea $\mu_i = E[Y_i]$ y supongamos que μ_i está en función de θ_i . En un modelo lineal generalizado existe una función g derivable y monótona tal que intentaremos expresar $g(\mu_i)$ como una combinación lineal de $p + 1$ variables explicativas x_{ij} con coeficientes los parámetros β_j , es decir,

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

La función g es conocida como **función enlace**. Normalmente tendremos β_0 como término independiente, así, $x_{i0} = 1$ para todo $i = 1, \dots, n$. La ecuación anterior también se puede expresar de forma matricial como

$$\tilde{\mathbf{g}}(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta},$$

siendo $\mathbf{X}$ una matriz de dimensión $n \times (p + 1)$ que tiene por filas los vectores $\mathbf{x}_i^\top$, y $\tilde{\mathbf{g}}$ una función vectorial cuyas componentes son $\tilde{g}_i(\boldsymbol{\mu}) = g(\mu_i)$.

En resumen, un modelo lineal generalizado tiene tres componentes:

1. Variables respuesta independientes $Y_1, \dots, Y_n$ con la misma distribución en la familia exponencial y en forma canónica
2. Un conjunto de parámetros $\boldsymbol{\beta}$ y variables explicativas $\mathbf{X}$
3. Una función enlace g derivable y monótona tal que

$$\tilde{\mathbf{g}}(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta}$$

con $\boldsymbol{\mu} = E[\mathbf{Y}]$

2.5 Estimación máximo verosímil

Recordemos que un estimador máximo verosímil $\hat{\theta}$ de un parámetro θ asociado a una distribución es aquel que maximiza la función de verosimilitud $L(\theta; y)$ o, de igual manera, la función de log-verosimilitud $l(\theta; y) = \ln(L(\theta; y))$. En los GLM este estimador siempre existe y es único [2].

Para hallarlo, es necesario resolver la ecuación $U(\theta; y) = \frac{\partial l}{\partial \theta}(\theta; y) = 0$, que no siempre va a ser posible analíticamente, así que tendremos que utilizar métodos numéricos. Uno de los más usados es el método de Newton-Raphson, que consiste en elegir un valor $\theta^{(0)}$, próximo al cero de la función y con derivada no nula, y construir la sucesión

$$\theta^{(m)} = \theta^{(m-1)} - \frac{U^{(m-1)}}{U'^{(m-1)}}$$

siendo $U^{(m-1)} = U(\theta^{(m-1)}; y)$ y de igual manera con $U'^{(m-1)}$.

Si en vez de U' , lo aproximamos por su valor esperado $E[U']$ en la ecuación anterior, como $E[U'] = -\mathfrak{J}$, nos queda lo siguiente

$$\theta^{(m)} = \theta^{(m-1)} + \frac{U^{(m-1)}}{\mathfrak{J}^{(m-1)}}. \quad (2.8)$$

Esto se conoce como el **método de scoring** [3] y converge en probabilidad al estimador [4].

Veamos como aplicar este método en el caso vectorial. Sean $Y_1, \dots, Y_n$ n variables aleatorias independientes que satisfacen las propiedades de un GLM. Para cada Y_i , la función de log-verosimilitud es:

$$l_i(\theta_i; y_i) = y_i b(\theta_i) + c(\theta_i) + d(y_i). \quad (2.9)$$

Además, recordemos que

$$E[Y_i] = \mu_i = -\frac{c'(\theta_i)}{b'(\theta_i)} \quad (2.10)$$

$$\text{var}[Y_i] = \frac{b''(\theta_i)c'(\theta_i) - c''(\theta_i)b'(\theta_i)}{(b'(\theta_i))^3} \quad (2.11)$$

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} =: \eta_i \quad (2.12)$$

La función de log-verosimilitud para todas las Y_i es

$$l(\boldsymbol{\theta}; \mathbf{y}) = \sum_{i=1}^n l_i(\theta_i; y_i) = \sum_{i=1}^n y_i b(\theta_i) + \sum_{i=1}^n c(\theta_i) + \sum_{i=1}^n d(y_i).$$

Para obtener el estimador máximo verosímil de los parámetros $\boldsymbol{\beta}$ necesitamos la función score

$$\mathbf{U}(\boldsymbol{\beta}; \mathbf{y}) = \nabla_{\boldsymbol{\beta}} l(\boldsymbol{\beta}; \mathbf{y}),$$

es decir,

$$(U_0(\boldsymbol{\beta}; \mathbf{y}), \dots, U_p(\boldsymbol{\beta}; \mathbf{y})) = \left(\frac{\partial l}{\partial \beta_0}(\boldsymbol{\beta}; \mathbf{y}), \dots, \frac{\partial l}{\partial \beta_p}(\boldsymbol{\beta}; \mathbf{y}) \right);$$

y, volviendo a considerar $\mathbf{U}$ como un vector aleatorio, también necesitamos su matriz de varianza-covarianza, que llamaremos **matriz de información**

$$\mathfrak{J} = (\mathfrak{J}_{jk}) = (\text{cov}[U_j, U_k]).$$

Proposición 12. Para todo $j = 0, 1, \dots, p$, la componente j -ésima de la función score $\mathbf{U}$ viene dada por

$$U_j = \sum_{i=1}^n \left[\frac{(y_i - \mu_i)}{\text{var}[Y_i]} x_{ij} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right]$$

Demostración. Utilizando la regla de la cadena tenemos

$$U_j = \frac{\partial l}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial l_i}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial l_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \beta_j}. \quad (2.13)$$

Calculemos las tres derivadas por separado. Derivando (2.9) respecto de θ_i y sustituyendo (2.10) obtenemos

$$\frac{\partial l_i}{\partial \theta_i} = y_i b'(\theta_i) + c'(\theta_i) = b'(\theta_i) \left(y_i + \frac{c'(\theta_i)}{b'(\theta_i)} \right) = b'(\theta_i) (y_i - \mu_i).$$

Luego, derivando (2.10) respecto de θ_i y utilizando la proposición 6.ii tenemos

$$\frac{\partial \mu_i}{\partial \theta_i} = \frac{b''(\theta_i)c'(\theta_i) - b'(\theta_i)c''(\theta_i)}{(b'(\theta_i))^2} = b'(\theta_i)\text{var}[Y_i],$$

entonces,

$$\frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{\frac{\partial \mu_i}{\partial \theta_i}} = \frac{1}{b'(\theta_i)\text{var}[Y_i]}.$$

Por último, utilizando la regla de la cadena y (2.12) tenemos

$$\frac{\partial \mu_i}{\partial \beta_j} = \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_j} = \frac{\partial \mu_i}{\partial \eta_i} x_{ij}.$$

Sustituyendo todo en (2.13) concluimos que

$$U_j = \sum_{i=1}^n \frac{\partial l_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \beta_j} = \sum_{i=1}^n \frac{b'(\theta_i)(y_i - \mu_i)}{b'(\theta_i)\text{var}[Y_i]} \cdot \frac{\partial \mu_i}{\partial \eta_i} x_{ij} = \sum_{i=1}^n \left[\frac{(y_i - \mu_i)}{\text{var}[Y_i]} x_{ij} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right]$$

□

Proposición 13. Para todo $j = 0, 1, \dots, p$ se tiene

$$E[U_j] = 0$$

Demostración. Utilizando la expresión de la proposición 12 y la linealidad de la esperanza deducimos

$$E[U_j] = E \left[\sum_{i=1}^n \left[\frac{(Y_i - \mu_i)}{\text{var}[Y_i]} x_{ij} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right] \right] = \sum_{i=1}^n \left[\frac{E[Y_i] - \mu_i}{\text{var}[Y_i]} x_{ij} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right] = 0$$

□

Proposición 14. La expresión de los elementos de la matriz de información $\mathfrak{J}$ de dimensión $(p+1) \times (p+1)$ viene dada por

$$\mathfrak{J}_{jk} = \sum_{i=1}^n \frac{x_{ij}x_{ik}}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2$$

Demostración. Por la proposición anterior se tiene que

$$\mathfrak{J}_{jk} = \text{cov}[U_j, U_k] = E[U_j U_k] = E \left[\sum_{i=1}^n \left[\frac{(Y_i - \mu_i)}{\text{var}[Y_i]} x_{ij} \left(\frac{\partial \mu_i}{\partial \eta_i} \right) \right] \sum_{l=1}^n \left[\frac{(Y_l - \mu_l)}{\text{var}[Y_l]} x_{lk} \left(\frac{\partial \mu_l}{\partial \eta_l} \right) \right] \right].$$

Como las Y_i 's son independientes se tiene $E[(Y_i - \mu_i)(Y_l - \mu_l)] = 0$ para todo $i \neq l$. Por consiguiente, utilizando la linealidad de la esperanza y la definición de varianza tenemos

$$\mathfrak{J}_{jk} = \sum_{i=1}^n \frac{E[(Y_i - \mu_i)^2]}{(\text{var}[Y_i])^2} x_{ij}x_{ik} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 = \sum_{i=1}^n \frac{x_{ij}x_{ik}}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

□

La ecuación de estimación (2.8) para el método de scoring generaliza vectorialmente a

$$\mathbf{b}^{(m)} = \mathbf{b}^{(m-1)} + [\mathfrak{J}^{(m-1)}]^{-1} \mathbf{U}^{(m-1)}. \quad (2.14)$$

donde $\mathbf{b}^{(m)}$ es el vector de estimación de los parámetros $\boldsymbol{\beta}$ en la iteración m -ésima. $[\mathfrak{J}^{(m-1)}]^{-1}$ es la inversa de la matriz de información con elementos $\mathfrak{J}_{jk}$, cuya expresión viene dada en la proposición 14, y $\mathbf{U}^{(m-1)}$ es la función score vectorial con elementos U_j , cuya expresión viene dada en la proposición 12, ambos evaluados en $\mathbf{b}^{(m-1)}$.

Si multiplicamos la ecuación (2.14) por $\mathfrak{J}^{(m-1)}$ nos queda lo siguiente

$$\mathfrak{J}^{(m-1)} \mathbf{b}^{(m)} = \mathfrak{J}^{(m-1)} \mathbf{b}^{(m-1)} + \mathbf{U}^{(m-1)}. \quad (2.15)$$

De la expresión de los elementos de $\mathfrak{J}$ podemos deducir que

$$\mathfrak{J} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

Siendo $\mathbf{W}$ la matriz diagonal $n \times n$ de elementos

$$w_{ii} = \frac{1}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

Por otro lado, la expresión de la derecha de (2.15) es un vector que tiene por elementos

$$\sum_{k=0}^p \sum_{i=1}^n \frac{x_{ij} x_{ik}}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 b_k^{(m-1)} + \sum_{i=1}^n \frac{(y_i - \mu_i) x_{ij}}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right),$$

para $j = 0, 1, \dots, p$. Esto se puede reescribir como

$$\sum_{i=1}^n \frac{x_{ij}}{\text{var}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \left[\sum_{k=0}^p x_{ik} b_k^{(m-1)} + (y_i - \mu_i) \left(\frac{\partial \eta_i}{\partial \mu_i} \right) \right].$$

Así, podemos expresar el lado derecho como $\mathbf{X}^\top \mathbf{W} \mathbf{z}$ siendo $\mathbf{z}$ el vector que tiene por elementos

$$z_i = \left[\sum_{k=0}^p x_{ik} b_k^{(m-1)} + (y_i - \mu_i) \left(\frac{\partial \eta_i}{\partial \mu_i} \right) \right],$$

para $i = 1, \dots, n$. De esta forma, la ecuación (2.15) se puede escribir como

$$\mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{X} \mathbf{b}^{(m)} = \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)}, \quad (2.16)$$

donde hemos resaltado la dependencia de $\mathbf{W}$ y $\mathbf{z}$ en $\mathbf{b}^{(m-1)}$.

2.6 Inferencia

Las dos principales herramientas de inferencia estadística son los **intervalos de confianza** y los **contrastes de hipótesis**. La primera consiste en calcular un intervalo mediante un método aplicado a una muestra aleatoria simple, de forma que un porcentaje previamente fijado (en la mayoría de casos 95 %) de los intervalos calculados por este método contienen el parámetro real. Su amplitud proporciona una medida de la precisión con la que se pueden hacer inferencias. Por otro lado, los contrastes de hipótesis consisten

en evaluar, mediante un estadístico y un nivel de significación, si los datos aportan suficiente evidencia para rechazar una hipótesis nula frente a una alternativa.

En el contexto de los GLM, un contraste de hipótesis es un procedimiento para evaluar si un conjunto concreto de parámetros cumple ciertas restricciones frente a un modelo más general. Es decir, los dos modelos deben tener la misma distribución de probabilidad y la misma función de enlace, pero la componente lineal de un modelo tiene más parámetros que el otro. El modelo más simple, que corresponde a la hipótesis nula H_0 , debe ser un caso especial del otro modelo más general. Si el modelo más simple se ajusta a los datos tan bien como el modelo más general, se prefiere por ser más sencillo y se conserva H_0 . Si el modelo más general se ajusta significativamente mejor, se rechaza H_0 en favor de una hipótesis alternativa H_1 , que corresponde al modelo más general. Para realizar estas comparaciones, utilizamos estadísticos de resumen para describir qué tan bien se ajustan los modelos a los datos. Estos **estadísticos de bondad de ajuste** pueden basarse en el valor máximo de la función de verosimilitud, el valor máximo de la función de log-verosimilitud, el valor mínimo del criterio de suma de cuadrados o un estadístico compuesto basado en los residuos. El proceso y la lógica se pueden resumir de la siguiente manera:

1. Especificamos un modelo M_0 correspondiente a la hipótesis nula H_0 y un modelo más general M_1 , siendo M_0 un caso particular de M_1 .
2. Ajustamos M_0 y calculamos el estadístico de bondad de ajuste G_0 . De igual manera con M_1 , calculamos G_1 .
3. Calculamos la mejora de ajuste, normalmente con $G_1 - G_0$, pero $\frac{G_1}{G_0}$ es otra opción.
4. Usamos la distribución muestral de $G_1 - G_0$ (o algún estadístico relacionado) para comprobar la hipótesis nula $G_1 = G_0$ contra la hipótesis alternativa $G_1 \neq G_0$.
5. Si la hipótesis nula $G_1 = G_0$ no se rechaza, preferimos el modelo M_0 . Por el contrario, si $G_1 \neq G_0$ se rechaza, entonces preferimos el modelo M_1 .

Los intervalos de confianza y los contrastes de hipótesis requieren distribuciones muestrales. Para calcular el intervalo de confianza necesitamos la distribución del estimador, y para el test de hipótesis necesitamos la distribución del estadístico de bondad de ajuste.

Si las variables respuesta siguen la distribución normal, las distribuciones muestrales usadas para la inferencia a menudo se pueden determinar con exactitud. Para otras distribuciones necesitamos confiar en resultados asintóticos de muestras grandes basados en el Teorema del Límite Central.

La idea básica si se dan las condiciones apropiadas es que si S es un estadístico de interés, entonces aproximadamente

$$\frac{S - E[S]}{\sqrt{\text{var}[S]}} \sim N(0, 1)$$

o, de forma equivalente

$$\frac{(S - E[S])^2}{\text{var}[S]} \sim \chi^2(1).$$

Para el caso vectorial tenemos que si $\mathbf{S} = (S_0, S_1, \dots, S_p)^\top$ es un vector de estadísticos con matriz de varianza-covarianza $\mathbf{V}$ no singular, entonces aproximadamente

$$(\mathbf{S} - E[\mathbf{S}])^\top \mathbf{V}^{-1} (\mathbf{S} - E[\mathbf{S}]) \sim \chi^2(p+1)$$

2.6.1 Distribución muestral del estadístico score

Sean $Y_1, \dots, Y_n$ n variables independientes en un GLM con parámetros $\boldsymbol{\beta}$, donde $E[Y_i] = \mu_i$ y $g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$.

Por la proposición 13 tenemos $E[\mathbf{U}] = \mathbf{0}$ y la matriz de varianza-covarianza $\mathfrak{J}$ viene dada por la proposición 14.

Si solo hay un parámetro β , el estadístico de score tiene la distribución asintótica

$$\frac{U}{\sqrt{\mathfrak{J}}} \sim N(0, 1), \text{ o de manera equivalente, } \frac{U^2}{\mathfrak{J}} \sim \chi^2(1).$$

En el caso vectorial tenemos la distribución asintótica

$$\mathbf{U}^\top \mathfrak{J}^{-1} \mathbf{U} \sim \chi^2(p+1). \quad (2.17)$$

2.6.2 Aproximaciones por series de Taylor

Para obtener las distribuciones muestrales asintóticas para varios otros estadísticos, es útil usar aproximaciones por series de Taylor. Recordemos que la serie de Taylor de una función $f \in \mathcal{C}^\infty(\mathbb{R})$ alrededor de un punto x_0 viene dada por

$$f(x) = \sum_{n=0}^{+\infty} \frac{(x - x_0)^n}{n!} f^{(n)}(x_0).$$

Si aproximamos la función de log-verosimilitud de un único parámetro β con los primeros tres términos de la serie de Taylor alrededor de una estimación b tenemos

$$l(\beta) \approx l(b) + (\beta - b)U(b) + \frac{(\beta - b)^2}{2} U'(b).$$

Aproximando U' por su valor esperado $E[U'] = -\mathfrak{J}$, la expresión queda

$$l(\beta) \approx l(b) + (\beta - b)U(b) - \frac{(\beta - b)^2}{2} \mathfrak{J}(b).$$

La aproximación correspondiente para la función de log-verosimilitud de un vector de parámetros $\boldsymbol{\beta}$ es

$$l(\boldsymbol{\beta}) \approx l(\mathbf{b}) + (\boldsymbol{\beta} - \mathbf{b})^\top \mathbf{U}(\mathbf{b}) - \frac{1}{2} (\boldsymbol{\beta} - \mathbf{b})^\top \mathfrak{J}(\mathbf{b}) (\boldsymbol{\beta} - \mathbf{b}). \quad (2.18)$$

Para la función score de un único parámetro β , la aproximación por los dos primeros términos de la serie de Taylor alrededor de una estimación b es

$$U(\beta) \approx U(b) + (\beta - b)U'(b).$$

Si aproximamos U' por su valor esperado $E[U'] = -\mathfrak{J}$, la expresión queda

$$U(\beta) \approx U(b) - (\beta - b)\mathfrak{J}(b).$$

La expresión correspondiente para un vector de parámetros $\boldsymbol{\beta}$ es

$$\mathbf{U}(\boldsymbol{\beta}) \approx \mathbf{U}(\mathbf{b}) - \mathfrak{J}(\mathbf{b})(\boldsymbol{\beta} - \mathbf{b}). \quad (2.19)$$

2.6.3 Distribución muestral de los estimadores máximo-verosímiles

La ecuación (2.19) se puede usar para obtener la distribución del estimador máximo-verosímil $\mathbf{b} = \hat{\boldsymbol{\beta}}$. Por definición, $\mathbf{b}$ es el estimador que maximiza $l(\mathbf{b})$ y, por lo tanto, $\mathbf{U}(\mathbf{b}) = \mathbf{0}$. Entonces,

$$\mathbf{U}(\boldsymbol{\beta}) \approx -\mathfrak{J}(\mathbf{b})(\boldsymbol{\beta} - \mathbf{b})$$

o, equivalentemente,

$$(\mathbf{b} - \boldsymbol{\beta}) \approx \mathfrak{J}^{-1} \mathbf{U},$$

siempre que $\mathfrak{J}$ sea no singular. Si $\mathfrak{J}$ se considera constante, luego $E[\mathbf{b} - \boldsymbol{\beta}] = \mathbf{0}$, ya que $E[\mathbf{U}] = \mathbf{0}$. Entonces, $E[\mathbf{b}] = \boldsymbol{\beta}$, al menos asintóticamente, así $\mathbf{b}$ es un estimador consistente de $\boldsymbol{\beta}$. La matriz de varianza-covarianza de $\mathbf{b}$ es

$$E[(\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})^\top] = E[\mathfrak{J}^{-1} \mathbf{U} \mathbf{U}^\top (\mathfrak{J}^{-1})^\top] = \mathfrak{J}^{-1} E[\mathbf{U} \mathbf{U}^\top] \mathfrak{J}^{-1} = \mathfrak{J}^{-1} \mathfrak{J} \mathfrak{J}^{-1} = \mathfrak{J}^{-1}.$$

La distribución muestral asintótica para $\mathbf{b}$ es

$$(\mathbf{b} - \boldsymbol{\beta})^\top \mathfrak{J}(\mathbf{b})(\mathbf{b} - \boldsymbol{\beta}) \sim \chi^2(p+1). \quad (2.20)$$

Esto se llama el **estadístico de Wald**. Para los casos de un parámetro es más común usar

$$b \sim N(\beta, \mathfrak{J}^{-1}). \quad (2.21)$$

Si las variables respuesta en el GLM tienen distribución normal, entonces (2.20) y (2.21) son resultados exactos.

2.6.4 Estadístico de ratio de log-verosimilitud

Definición 15. Un **modelo saturado** es el modelo más general con el máximo número de parámetros que se pueden estimar. El número de parámetros del modelo saturado es igual al número de componentes lineales potencialmente diferentes, que puede ser menor que el número de observaciones. Se utiliza para evaluar la exactitud de modelos más particulares.

En general, sea $m+1$ el número máximo de parámetros que se pueden estimar. Sean $\boldsymbol{\beta}_{\max}$ el vector de parámetros para el modelo saturado y $\mathbf{b}_{\max}$ su estimador máximo-verosímil. El valor de la función de verosimilitud evaluada en $\mathbf{b}_{\max}$, $L(\mathbf{b}_{\max}; \mathbf{y})$ será mayor que cualquier otro valor de la función para esas observaciones, ya que proporciona la descripción más completa de los datos.

Definición 16. Sea $L(\mathbf{b}; \mathbf{y})$ el valor de máximo de la función de verosimilitud de un modelo de interés. El **ratio de verosimilitud** viene dado por

$$\lambda = \frac{L(\mathbf{b}_{\max}; \mathbf{y})}{L(\mathbf{b}; \mathbf{y})}$$

y nos proporciona una forma de evaluar la bondad de ajuste del modelo.

Definición 17. La **devianza** o **estadístico de ratio de log-verosimilitud** es el doble del logaritmo del ratio de verosimilitud

$$D = 2 \ln(\lambda) = 2 (l(\mathbf{b}_{\max}; \mathbf{y}) - l(\mathbf{b}; \mathbf{y})).$$

Es un estadístico más usado que el ratio de verosimilitud ya que sigue una distribución chi-cuadrado, con lo que podremos determinar la región crítica.

Valores altos de D sugieren que el modelo de interés es una descripción pobre de los datos en comparación al modelo saturado.

2.6.5 Distribución muestral de la devianza

Por la ecuación (2.18), si $\mathbf{b}$ es el estimador máximo-verosímil del vector de parámetros $\boldsymbol{\beta}$ (de modo que $\mathbf{U}(\mathbf{b}) = \mathbf{0}$),

$$l(\boldsymbol{\beta}) - l(\mathbf{b}) \approx -\frac{1}{2} (\boldsymbol{\beta} - \mathbf{b})^\top \mathfrak{J}(\mathbf{b}) (\boldsymbol{\beta} - \mathbf{b}).$$

Entonces, el estadístico

$$2 (l(\mathbf{b}; \mathbf{y}) - l(\boldsymbol{\beta}; \mathbf{y})) = (\boldsymbol{\beta} - \mathbf{b})^\top \mathfrak{J}(\mathbf{b}) (\boldsymbol{\beta} - \mathbf{b})$$

sigue la distribución $\chi^2(p+1)$, donde $p+1$ es el número de parámetros, por (2.20).

De este resultado, se sigue la distribución muestral de la devianza. Tenemos que

$$\begin{aligned} D &= 2 (l(\mathbf{b}_{\max}; \mathbf{y}) - l(\mathbf{b}; \mathbf{y})) \\ &= 2 (l(\mathbf{b}_{\max}; \mathbf{y}) - l(\boldsymbol{\beta}_{\max}; \mathbf{y})) - 2 (l(\mathbf{b}; \mathbf{y}) - l(\boldsymbol{\beta}; \mathbf{y})) + 2 (l(\boldsymbol{\beta}_{\max}; \mathbf{y}) - l(\boldsymbol{\beta}; \mathbf{y})). \end{aligned} \quad (2.22)$$

El primer término de (2.22) tiene la distribución $\chi^2(m+1)$, donde $m+1$ es el número de parámetros del modelo saturado; el segundo término tiene la distribución $\chi^2(p+1)$, donde $p+1$ es el número de parámetros del modelo de interés; y el tercer término, $v = 2 (l(\boldsymbol{\beta}_{\max}; \mathbf{y}) - l(\boldsymbol{\beta}; \mathbf{y}))$, es una constante positiva que será cercana a cero si el modelo de interés se ajusta a los datos casi tan bien como se ajusta el modelo saturado. Por lo tanto, la distribución muestral de la devianza será aproximadamente

$$\chi^2(m-p, v),$$

donde v es el parámetro de no centralidad. La devianza constituye la base de la mayoría de las pruebas de hipótesis para GLM.

Si las variables respuesta Y_i siguen la distribución normal, entonces D sigue exactamente la distribución chi-cuadrado no central. Sin embargo, en este caso, D depende de $\text{var}[Y_i] = \sigma^2$, que en la práctica es generalmente desconocido. Esto significa que D no se puede usar directamente como estadístico de bondad de ajuste.

Para las Y_i con otras distribuciones, la distribución de D puede ser solo aproximadamente chi-cuadrado. Sin embargo, para las distribuciones Binomial y Poisson, por ejemplo, D se puede calcular y utilizar directamente como un estadístico de bondad de ajuste.

2.6.6 Contrastes de hipótesis

Se pueden comprobar hipótesis sobre un vector de parámetros β de longitud $p + 1$ usando la distribución del estadístico de Wald $(\hat{\beta} - \beta)^\top \mathfrak{J}(\hat{\beta})(\hat{\beta} - \beta) \sim \chi^2(p + 1)$, de (2.20). Ocasionalmente, también se usa el estadístico score: $U^\top \mathfrak{J}^{-1} U \sim \chi^2(p + 1)$, de (2.17).

Un enfoque alternativo es comparar la bondad de ajuste de dos modelos. Estos modelos tienen que ser **anidados** o **jerárquicos**, es decir, deben tener la misma distribución y función enlace, pero la componente lineal del modelo más simple M_0 es un caso particular de la componente lineal del modelo más general M_1 .

Consideremos la hipótesis nula

$$H_0 : \beta = \beta_0 = (\beta_0, \beta_1, \dots, \beta_q)^\top$$

correspondiente al modelo más simple M_0 y una hipótesis más general

$$H_1 : \beta = \beta_1 = (\beta_0, \beta_1, \dots, \beta_p)^\top$$

correspondiente a M_1 , con $q < p < n$.

Podemos probar H_0 contra H_1 usando la diferencia del estadístico de devianza

$$\begin{aligned} \Delta D &= D_0 - D_1 = 2(l(\mathbf{b}_{\max}; y) - l(\mathbf{b}_0; y)) - 2(l(\mathbf{b}_{\max}; y) - l(\mathbf{b}_1; y)) \\ &= 2(l(\mathbf{b}_1; y) - l(\mathbf{b}_0; y)) \end{aligned}$$

Si los dos modelos describen bien los datos, entonces $D_0 \sim \chi^2(m - q)$ y $D_1 \sim \chi^2(m - p)$ así que $\Delta D \sim \chi^2(p - q)$. Si el valor de ΔD es consistente con la distribución $\chi^2(p - q)$, entonces elegiríamos el modelo M_0 correspondiente a H_0 , por ser más simple. De este modo, utilizaríamos la Navaja de Ockham, aunque este principio debe tener en cuenta la importancia práctica de los parámetros adicionales.

Si M_0 no describe bien los datos, D_0 sería más grande de lo esperado. De hecho, la distribución de D_0 podría ser mejor explicada por una distribución chi-cuadrado no central. Si M_1 describe bien los datos, al contrario de M_0 , entonces ΔD sería mayor de lo esperado.

Este resultado se usa para probar la hipótesis H_1 del siguiente modo: si el valor ΔD se encuentra en la región crítica (i.e., por encima del percentil $100 \times \alpha$ de la distribución $\chi^2(p - q)$), rechazaríamos H_0 en favor de H_1 dado que M_1 proporcionaría una significante mejor descripción de los datos (a pesar de que también podría no ajustarse bien a los datos).

Siempre que la devianza se pueda calcular a partir de los datos, ΔD nos da un buen método para los contrastes de hipótesis. La distribución muestral de ΔD se aproxima generalmente mejor por la distribución chi-cuadrado que una sola devianza.

Sin embargo, modelos basados en la distribución normal u otras distribuciones con parámetros molestos no estimados, la devianza no se podría calcular a partir de los datos. En estos casos, habría que calcular otros estadísticos, como por ejemplo la F de Fisher

$$F = \frac{D_0 - D_1}{p - q} \bigg/ \frac{D_1}{n - p}.$$

Si H_0 es correcta, F tendrá la distribución $F(p - q, n - p)$, al menos aproximadamente. Si no lo es, el valor de F será más grande de lo esperado.

ADAPTACIÓN DE LOS MODELOS LINEALES GENERALIZADOS A DATOS DE CONTEO SOBREDISPERSOS

En este segundo capítulo nos centraremos en un caso de los GLM: la regresión binomial negativa, que surge como una extensión natural del GLM de Poisson cuando los datos de conteo presentan sobredispersión, es decir, que la varianza exceda notablemente a la media.

Los modelos de regresión de Poisson asumen que la media y la varianza de la variable respuesta son iguales (esto es, $E[Y] = \text{Var}(Y)$), lo que se conoce como equidispersión. Sin embargo, en la práctica es frecuente observar sobredispersión. En esos casos, el modelo Poisson tiende a infravalorar la probabilidad de observar valores altos, dando lugar a errores sistemáticos en la estimación de los parámetros y de las incertidumbres asociadas.

La regresión Binomial Negativa soluciona ese inconveniente al permitir que la varianza sea mayor que la media mediante un parámetro adicional de sobredispersión α , cumpliendo:

$$\text{Var}(Y) = E[Y] + \alpha (E[Y])^2.$$

De este modo, si los conteos presentan una variabilidad superior a la que asumiría un modelo Poisson, la Binomial Negativa constituye una elección más adecuada y reduce el sesgo en las estimaciones.

A lo largo del capítulo veremos en qué consiste la distribución Binomial Negativa (Negative Binomial (NB), por sus siglas en inglés), veremos cómo ajustar un modelo de regresión basado en esta distribución y calcularemos la devianza, el estadístico de bondad de ajuste. Finalmente, explicaremos diferentes retos que se nos pueden plantear en los conjuntos de datos (temporalidad, datos composicionales y datos anidados) y cómo los abordaremos en nuestro modelo [5].

3.1 Distribución Binomial Negativa

Recordemos que una variable aleatoria X sigue una distribución geométrica con parámetro $p \in (0, 1)$, $X \sim \text{Geo}(p)$, si modela el número de fracasos antes del primer éxito en una serie de experimentos Bernoulli con probabilidad de éxito p . La distribución NB generaliza esta distribución a un número cualquiera de éxitos.

Definición 18. Diremos que una variable aleatoria X sigue una **distribución Binomial Negativa (NB)** con parámetros $r \in \mathbb{Z}^{>0}$, $p \in (0, 1)$, $X \sim \text{NB}(r, p)$, si modela el número de fracasos antes del r -ésimo éxito en una serie de experimentos Bernoulli con probabilidad de éxito p .

Deduzcamos la función de probabilidad de la distribución binomial negativa. Sea Y una variable aleatoria que sigue una distribución $\text{NB}(r, p)$ y calculemos $P(Y = y)$, donde y es el número de fracasos antes del r -ésimo éxito. Sea x el intento donde se consigue el r -ésimo éxito. Se sigue que los otros $r - 1$ éxitos pueden tener lugar en cualquiera de los $x - 1$ intentos. Expresado como una combinación tenemos

$$\binom{x-1}{r-1}$$

formas de obtener el r -ésimo éxito en el x -ésimo evento. Cada una de estas combinaciones tiene una probabilidad $p^r (1-p)^{x-r}$, lo que nos da la probabilidad de $x - r$ fracasos antes del r -ésimo éxito. Notemos que $y = x - r$, lo que nos da

$$f(y; p, r) = P(Y = y) = \binom{y+r-1}{r-1} p^r (1-p)^y. \quad (3.1)$$

La distribución NB también se puede expresar a partir de otros dos parámetros. Sean $\mu = E[Y]$ y $\alpha = \frac{1}{p}$. Recordemos que en el Cuadro 2.1 vimos que la distribución NB pertenece a la familia exponencial en forma canónica, considerando r como *parámetro molesto*. De esta forma, aplicando la proposición 6.i tenemos

$$\mu = E[Y] = -\frac{c'(p)}{b'(p)} = -\frac{\frac{r}{p}}{-\frac{1}{1-p}} = \frac{r(1-p)}{p} = \frac{(1-p)}{\alpha p}.$$

Aislado p obtenemos

$$p = \frac{1}{1 + \alpha \mu}.$$

Así, podemos reescribir la función de probabilidad (3.1) como

$$f(y; \mu, \alpha) = \binom{y + \frac{1}{\alpha} - 1}{\frac{1}{\alpha} - 1} \left(\frac{1}{1 + \alpha \mu} \right)^{\frac{1}{\alpha}} \left(\frac{\alpha \mu}{1 + \alpha \mu} \right)^y$$

Calculemos la varianza de Y utilizando la proposición 6.ii

$$\text{Var}[Y] = \frac{b''(p)c'(p) - c''(p)b'(p)}{(b'(p))^3} = \frac{-\frac{1}{(1-p)^2} \cdot \frac{r}{p} - \left(-\frac{r}{p^2}\right) \cdot \left(-\frac{1}{1-p}\right)}{\left(-\frac{1}{1-p}\right)^3} = \frac{r(1-p)}{p^2},$$

que también podemos poner en función de μ y α como

$$\text{Var}[Y] = \frac{\frac{\alpha\mu}{1+\alpha\mu}}{\alpha\left(\frac{1}{1+\alpha\mu}\right)^2} = \mu + \alpha\mu^2.$$

3.2 Método de scoring aplicado a un vector aleatorio con distribución Binomial Negativa

Ahora, derivaremos la función de log-verosimilitud dentro del marco GLM y estimaremos los parámetros con el método de scoring.

Sean $Y_1, \dots, Y_n$, n variables aleatorias independientes con distribución NB. La función de log-verosimilitud para todos los Y_i es

$$l(\boldsymbol{\mu}; \mathbf{y}, \alpha) = \sum_{i=1}^n y_i \ln\left(\frac{\alpha\mu_i}{1+\alpha\mu_i}\right) - \frac{1}{\alpha} \ln(1+\alpha\mu_i) + \ln\left(\Gamma\left(y_i + \frac{1}{\alpha}\right)\right) - \ln(\Gamma(y_i + 1)) - \ln\left(\Gamma\left(\frac{1}{\alpha}\right)\right),$$

donde $\Gamma: \mathbb{R}^{>0} \rightarrow \mathbb{R}$ es la función gamma definida como

$$\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$$

y recordemos que para todo $n \in \mathbb{Z}^{>0}$, $\Gamma(n) = (n-1)!$.

Para aplicar un modelo lineal generalizado vamos a elegir como función enlace $g(\mu_i) = \ln(\mu_i) = \eta_i$, de donde $\mu_i = \exp(\eta_i)$. De aquí tenemos que $\frac{\partial \mu_i}{\partial \eta_i} = \exp(\eta_i)$. Si elegimos X_{ij} con $i = 1, \dots, n$ y $j = 0, \dots, p$ como variables explicativas, tenemos $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Así, la proposición 12 nos da la expresión de la función score $\mathbf{U}$:

$$U_j = \sum_{i=1}^n \left[\frac{(y_i - \exp(\mathbf{x}_i^\top \boldsymbol{\beta}))}{\exp(\mathbf{x}_i^\top \boldsymbol{\beta}) + \alpha \exp(2\mathbf{x}_i^\top \boldsymbol{\beta})} x_{ij} \exp(\mathbf{x}_i^\top \boldsymbol{\beta}) \right] = \sum_{i=1}^n \left[\frac{(y_i - \exp(\mathbf{x}_i^\top \boldsymbol{\beta}))}{1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})} x_{ij} \right]$$

y la proposición 14 nos da la expresión de la matriz de información $\mathfrak{J}$:

$$\mathfrak{J}_{jk} = \sum_{i=1}^n \frac{x_{ij} x_{ik}}{\exp(\mathbf{x}_i^\top \boldsymbol{\beta}) + \alpha \exp(2\mathbf{x}_i^\top \boldsymbol{\beta})} \exp(2\mathbf{x}_i^\top \boldsymbol{\beta}) = \sum_{i=1}^n \frac{x_{ij} x_{ik} \exp(\mathbf{x}_i^\top \boldsymbol{\beta})}{1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})}.$$

Sin embargo, notemos que estas dos expresiones dependen del parámetro α , el cual tendremos que estimar en la mayoría de casos. Nosotros lo estimaremos añadiéndolo en el método de scoring.

Consideramos la función score ampliada

$$\bar{\mathbf{U}} = (\mathbf{U}, U_\alpha) = (U_0, U_1, \dots, U_p, U_\alpha),$$

con

$$\begin{aligned} U_\alpha(\boldsymbol{\beta}, \mathbf{y}, \alpha) &= \frac{\partial l}{\partial \alpha}(\boldsymbol{\beta}, \mathbf{y}, \alpha) = \sum_{i=1}^n \frac{1}{\alpha^2} \left[\ln(1 + \alpha\mu_i) + \frac{\alpha(y_i - \mu_i)}{1 + \alpha\mu_i} - \psi\left(y_i + \frac{1}{\alpha}\right) + \psi\left(\frac{1}{\alpha}\right) \right] \\ &= \sum_{i=1}^n \frac{1}{\alpha^2} \left[\ln(1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})) + \frac{\alpha(y_i - \exp(\mathbf{x}_i^\top \boldsymbol{\beta}))}{1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})} - \psi\left(y_i + \frac{1}{\alpha}\right) + \psi\left(\frac{1}{\alpha}\right) \right], \end{aligned}$$

3. ADAPTACIÓN DE LOS MODELOS LINEALES GENERALIZADOS A DATOS DE CONTEO SOBREDISPERSOS

donde $\psi(x) = \frac{d}{dx} \ln(\Gamma(x)) = \frac{\Gamma'(x)}{\Gamma(x)}$. Esta función se conoce como **digamma**, la cual podemos aproximar numéricamente usando la fórmula de los tres puntos respecto del punto medio [6] mediante la ecuación:

$$\psi(x) \approx \frac{\ln(\Gamma(x+h)) - \ln(\Gamma(x-h))}{2h},$$

para un $h > 0$ lo suficientemente pequeño.

Calculemos ahora los elementos de la matriz Hessiana de l donde interviene el parámetro α :

$$\frac{\partial^2 l}{\partial \alpha \partial \beta_j}(\boldsymbol{\beta}, \mathbf{y}, \alpha) = - \sum_{i=1}^n \left[\frac{(y_i - \mu_i)}{(1 + \alpha \mu_i)^2} \mu_i x_{ij} \right] \quad (3.2)$$

$$\begin{aligned} \frac{\partial^2 l}{\partial \alpha^2}(\boldsymbol{\beta}, \mathbf{y}, \alpha) = \sum_{i=1}^n - \frac{1}{\alpha^3} & \left[\frac{\alpha(1 + 2\alpha \mu_i)(y_i - \mu_i) - \alpha \mu_i(1 + \alpha \mu_i)}{(1 + \alpha \mu_i)^2} + 2 \ln(1 + \alpha \mu_i) \right. \\ & \left. - 2 \left(\psi \left(y_i + \frac{1}{\alpha} \right) - \psi \left(\frac{1}{\alpha} \right) \right) - \frac{1}{\alpha} \left(\psi' \left(y_i + \frac{1}{\alpha} \right) - \psi' \left(\frac{1}{\alpha} \right) \right) \right]. \end{aligned} \quad (3.3)$$

La función ψ' se conoce como **trigamma** y se puede aproximar numéricamente usando la fórmula de derivación de los cinco puntos, [6]

$$\psi'(x) = \frac{-\ln(\Gamma(x+2h)) + 16\ln(\Gamma(x+h)) - 30\ln(\Gamma(x)) + 16\ln(\Gamma(x-h)) - \ln(\Gamma(x-2h))}{12h^2},$$

para un $h > 0$ lo suficientemente pequeño.

Recordemos que en el método de scoring no utilizamos directamente la Hessiana, si no que calculamos el opuesto de su esperanza, la matriz de información. Observemos que, por linealidad de la esperanza, (3.2) se anula. Por otro lado, en (3.3), tendremos que calcular las esperanzas de las funciones digamma y trigamma. Al no conocer una expresión de estas, utilizaremos directamente el valor de la función. Así, nuestra matriz de información ampliada será

$$\bar{\mathfrak{J}} = \begin{pmatrix} \mathfrak{J} & \mathfrak{J}_{\alpha\beta} \\ \mathfrak{J}_{\alpha\beta}^\top & \mathfrak{J}_\alpha \end{pmatrix},$$

siendo $\mathfrak{J}_{\alpha\beta}$ un vector que tiene por elementos

$$\mathfrak{J}_{\alpha\beta_j} = -E \left[- \sum_{i=1}^n \frac{(Y_i - \mu_i)}{(1 + \alpha \mu_i)^2} \mu_i x_{ij} \right] = \sum_{i=1}^n \frac{(E[Y_i] - \mu_i)}{(1 + \alpha \mu_i)^2} \mu_i x_{ij} = 0,$$

para $j = 0, 1, \dots, p$, es decir, $\mathfrak{J}_{\alpha\beta} = \mathbf{0}_{(p+1) \times 1}$; y $\mathfrak{J}_\alpha$ la aproximación del opuesto de la esperanza de (3.3) como

$$\begin{aligned} \mathfrak{J}_\alpha &= - \sum_{i=1}^n - \frac{1}{\alpha^3} \left[\frac{\alpha(1 + 2\alpha \mu_i)(E[Y_i] - \mu_i) - \alpha \mu_i(1 + \alpha \mu_i)}{(1 + \alpha \mu_i)^2} + 2 \ln(1 + \alpha \mu_i) + \phi(y_i, \alpha) \right] \\ &= \sum_{i=1}^n \frac{1}{\alpha^3} \left[- \frac{\alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})}{1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})} + 2 \ln(1 + \alpha \exp(\mathbf{x}_i^\top \boldsymbol{\beta})) + \phi(y_i, \alpha) \right], \end{aligned}$$

con $\phi(y_i, \alpha) = -2(\psi(y_i + \frac{1}{\alpha}) - \psi(\frac{1}{\alpha})) - \frac{1}{\alpha}(\psi'(y_i + \frac{1}{\alpha}) - \psi'(\frac{1}{\alpha}))$.

Una vez calculadas todas las expresiones necesarias, ya podemos dar la ecuación del método de scoring para estimar los parámetros β y α :

$$\begin{pmatrix} \mathfrak{J}^{(m-1)} & \mathbf{0}_{(p+1) \times 1} \\ \mathbf{0}_{(p+1) \times 1}^\top & \mathfrak{J}_\alpha^{(m-1)} \end{pmatrix} \begin{pmatrix} \mathbf{b}^{(m)} \\ a^{(m)} \end{pmatrix} = \begin{pmatrix} \mathfrak{J}^{(m-1)} & \mathbf{0}_{(p+1) \times 1} \\ \mathbf{0}_{(p+1) \times 1}^\top & \mathfrak{J}_\alpha^{(m-1)} \end{pmatrix} \begin{pmatrix} \mathbf{b}^{(m-1)} \\ a^{(m-1)} \end{pmatrix} + \begin{pmatrix} \mathbf{U}^{(m-1)} \\ U_\alpha^{(m-1)} \end{pmatrix},$$

donde $a^{(m)}$ y $\mathbf{b}^{(m)}$ son los estimadores de α y β , respectivamente, en la iteración m -ésima. Esta ecuación se puede desglosar en las siguientes dos ecuaciones

$$\begin{aligned} \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{X} \mathbf{b}^{(m)} &= \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)} \\ \mathfrak{J}_\alpha^{(m-1)} a^{(m)} &= \mathfrak{J}_\alpha^{(m-1)} a^{(m-1)} + U_\alpha^{(m-1)}, \end{aligned}$$

donde $\mathbf{W}^{(m-1)}$ es una matriz diagonal $n \times n$ que tiene por elementos

$$w_{ii}^{(m-1)} = \frac{\exp(\mathbf{x}_i^\top \mathbf{b}^{(m-1)})}{1 + a^{(m-1)} \exp(\mathbf{x}_i^\top \mathbf{b}^{(m-1)})}$$

y $\mathbf{z}^{(m-1)}$ es un vector de dimensión n que tiene por elementos

$$z_i^{(m-1)} = \sum_{k=0}^p \left[x_{ik} b_k^{(m-1)} + \frac{y_i - \exp(\mathbf{x}_i^\top \mathbf{b}^{(m-1)})}{\exp(\mathbf{x}_i^\top \mathbf{b}^{(m-1)})} \right].$$

3.3 Cálculo de la devianza

Recordemos que para ver si un modelo se ajusta bien en comparación a un modelo saturado, es decir, a un modelo que se ajusta perfectamente a los datos (esto se entiende como $\hat{y}_i = \hat{\mu}_i = y_i$, para todo $i = 1, \dots, n$), realizamos un test de hipótesis donde el estadístico de bondad de ajuste es la devianza

$$D = 2(l(\mathbf{b}_{\text{máx}}; \mathbf{y}, a) - l(\mathbf{b}; \mathbf{y}, a)),$$

donde $\mathbf{b}_{\text{máx}}$, $\mathbf{b}$ y a son los estimadores máximo-verosímiles del vector de parámetros del modelo saturado, del vector de parámetros del modelo dado y del parámetro α , respectivamente.

Para el modelo saturado usaremos que $\mu_i = E[Y_i] = y_i$ para todo $i = 1, \dots, n$. Así,

$$l(\mathbf{b}_{\text{máx}}; \mathbf{y}, a) = \sum_{i=1}^n y_i \ln \left(\frac{ay_i}{1 + ay_i} \right) - \frac{1}{a} \ln(1 + ay_i) + \ln \left(\Gamma \left(y_i + \frac{1}{a} \right) \right) - \ln(\Gamma(y_i + 1)) - \ln \left(\Gamma \left(\frac{1}{a} \right) \right).$$

Por consiguiente, la devianza tiene la expresión

$$\begin{aligned} D &= 2 \sum_{i=1}^n y_i \ln \left(\frac{y_i}{\mu_i} \cdot \frac{1 + a\mu_i}{1 + ay_i} \right) - \frac{1}{a} \ln \left(\frac{1 + ay_i}{1 + a\mu_i} \right) = 2 \sum_{i=1}^n y_i \ln \left(\frac{y_i}{\mu_i} \right) - \left(\frac{1}{a} + y_i \right) \ln \left(\frac{1 + ay_i}{1 + a\mu_i} \right) \\ &= 2 \sum_{i=1}^n y_i \ln \left(\frac{y_i}{\exp(\mathbf{x}_i^\top \mathbf{b})} \right) - \left(\frac{1}{a} + y_i \right) \ln \left(\frac{1 + ay_i}{1 + a \exp(\mathbf{x}_i^\top \mathbf{b})} \right) \\ &= 2 \sum_{i=1}^n y_i (\ln(y_i) - \mathbf{x}_i^\top \mathbf{b}) - \left(\frac{1}{a} + y_i \right) \ln \left(\frac{1 + ay_i}{1 + a \exp(\mathbf{x}_i^\top \mathbf{b})} \right). \end{aligned} \tag{3.4}$$

Una vez calculada la devianza D , se puede demostrar que si n es grande, la devianza se aproxima a una distribución ji-cuadrado con $n - p$ grados de libertad, como vimos en la subsección (2.6.5), por lo cual, el p -valor se calcula de la siguiente forma:

$$p = P(\chi^2(n - p) \geq D) = 1 - F_{\chi^2(n-p)}(D),$$

y se comprueba si este es menor que el nivel de significación, que en la mayoría de casos es 0,05. En tal caso, nuestro modelo no se ajustaría bien a los datos y, en caso contrario, sí lo haría.

Para realizar un test de hipótesis y comparar dos modelos, utilizaríamos como estadístico la diferencia de las desviaciones de los dos modelos. Consideremos la hipótesis nula

$$H_0 : (\boldsymbol{\beta}, \alpha) = (\beta_0, \beta_1, \dots, \beta_q, \alpha)^\top$$

y una hipótesis más general, donde mantenemos los parámetros anteriores y añadimos nuevos parámetros correspondientes a nuevas variables explicativas

$$H_1 : (\boldsymbol{\beta}, \alpha) = (\beta_0, \beta_1, \dots, \beta_q, \dots, \beta_p, \alpha)^\top,$$

con $q < p$. Sean $\mathbf{X}$ y $\mathbf{X}^*$ las matrices que contienen los valores de las variables explicativas correspondientes al modelo 0 y al modelo 1, respectivamente. Así, nuestro estadístico de bondad de ajuste tiene por expresión

$$\Delta D = D_0 - D_1 = 2 \sum_{i=1}^n y_i (\mathbf{x}_i^{*\top} \mathbf{b}_1 - \mathbf{x}_i^\top \mathbf{b}_0) - \left(\frac{1}{a} + y_i \right) \ln \left(\frac{1 + a \exp(\mathbf{x}_i^{*\top} \mathbf{b}_1)}{1 + a \exp(\mathbf{x}_i^\top \mathbf{b}_0)} \right). \quad (3.5)$$

Calculado este valor, comprobamos si se encuentra en la región crítica de la distribución $\chi^2(p - q)$. En tal caso, rechazaríamos la hipótesis H_0 en favor de H_1 ; si no, elegiríamos la hipótesis H_0 por simplicidad.

3.4 Inclusión de efectos aleatorios, temporales y composicionales

Tras haber explorado la regresión binomial negativa en el marco de los GLM para datos de conteo sobredispersos, estudiaremos el modelo particular que ajustaremos en el siguiente capítulo.

De momento hemos estudiado un modelo Binomial Negativo simple, cuya expresión sería

$$\ln(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \quad \forall i = 1, \dots, n$$

es decir,

$$\mu_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta}) \quad \forall i = 1, \dots, n.$$

Sin embargo, en algunos conjuntos de datos se pueden identificar los siguientes tres retos para el modelado de la variable respuesta:

1. **Capturar una tendencia temporal de forma no lineal:** para ello, introduciremos términos polinómicos capturando así posibles curvaturas en la trayectoria temporal de los datos.

2. **Ajustar la escala de cada observación mediante un *offset*:** en los datos composicionales, que representan partes relativas de un total, nos centramos en la proporción que representa nuestra variable respuesta respecto de un total que puede variar según la unidad muestral. Por eso, conviene añadir un término fijo al modelo —el *offset*— que normalice estas diferencias. Así, el modelo puede interpretarse en términos de proporciones, evitando comparar directamente conteos absolutos que no son homogéneos.
3. **Capturar la heterogeneidad no explicada mediante efectos mixtos:** cuando tenemos datos anidados (aquellos que presentan una organización jerárquica de datos dentro de una estructura [7]), es lógico suponer que cada grupo posee características intrínsecas que no se reflejan explícitamente en las covariables. Para recoger dicha variabilidad sin estimar un parámetro fijo para cada una, introducimos *efectos aleatorios*. Esto conduce a un Modelo Binomial Negativo con Efectos Mixtos (NBMM, por sus siglas en inglés), capaz de capturar las diferencias entre grupos más allá de las covariables medibles.

3.4.1 Ajuste temporal

Cuando tomamos muestras de una unidad muestral en diferentes instantes de tiempo nos genera una serie temporal. Para reflejar esta tendencia temporal incluiremos un término polinómico en la variable temporal en nuestro modelo.

Supongamos que tenemos n unidades muestrales y que se toman sus muestras en los instantes de tiempo $t_1 < \dots < t_J$, de forma que en total tendremos $n \cdot J$ mediciones. Lo primero que haremos será reescalar la variable temporal. Es decir, en la entrada correspondiente a t_j cambiaremos su valor por

$$t'_j = \frac{t_j - t_1}{t_J - t_1},$$

para todo $j = 1, \dots, J$. De esta forma, nuestra variable temporal tomará valores en el intervalo $[0, 1]$.

Ahora añadiremos al modelo el término polinómico en la variable temporal. Elegiremos un polinomio de grado 3 para capturar una gran posibilidad de variaciones en el tiempo. Así, nuestro modelo queda

$$\ln(\mu_{ij}) = \beta_0 + \beta_1 x_{ij,1} + \beta_2 x_{ij,2} + \dots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j,$$

es decir,

$$\mu_{ij} = \exp\left(\beta_0 + \beta_1 x_{ij,1} + \beta_2 x_{ij,2} + \dots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j\right).$$

A partir de esta expresión podemos justificar el porqué del reescalado de la parte temporal. Notemos que si el tiempo pudiera tomar valores relativamente altos, al elevarlo al cubo y luego aplicarle la exponencial podríamos tener errores de *overflow*¹. Al fijar el tiempo en valores dentro del intervalo $[0, 1]$ lo evitamos.

¹ situación donde una operación aritmética produce un resultado que excede la capacidad del espacio de almacenamiento asignado para almacenarlo

3.4.2 Ajuste por tamaño: uso del *offset*

Cuando la variable respuesta Y_{ij} no se interpreta de manera aislada sino como parte de un total, no tiene sentido comparar el conteo absoluto de una unidad muestral con el de otra, ya que los totales pueden ser diferentes. Por lo tanto, para capturar esta estructura composicional, introducimos un *offset* que normalice el tamaño de cada observación.

Sea N_{ij} el número total de conteos en la unidad muestral i y el tiempo t_j , que suele ser un dato conocido en los conjuntos de datos, y por lo tanto no lo debemos estimar. Incorporar el *offset* equivale a sumar $\ln(N_{ij})$ en la parte lineal del modelo. De esta forma podemos plantear nuestro modelo como

$$\ln(\mu_{ij}) = \ln(N_{ij}) + \beta_0 + \beta_1 x_{ij,1} + \cdots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j,$$

es decir,

$$\mu_{ij} = N_{ij} \exp\left(\beta_0 + \beta_1 x_{ij,1} + \cdots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j\right).$$

En esta última expresión podemos ver que la parte exponencial se interpreta como la proporción de conteos, y N_{ij} ajusta la escala al total.

3.4.3 Capturar la heterogeneidad entre grupos: efectos mixtos

Hasta ahora hemos introducido una variable temporal para capturar la tendencia a lo largo del tiempo y un *offset* para normalizar el tamaño de cada observación. Para finalizar el capítulo y tener nuestro modelo final introduciremos efectos aleatorios. Esto nos permite capturar la variabilidad no explicada por las covariables cuando existen estructuras jerárquicas o mediciones repetidas dentro de grupos a lo largo del tiempo. A nivel conceptual, el modelo asume que toda la información común a un grupo (pero no recogida en las covariables) se modela mediante *efectos aleatorios*, que se trata como una realización de una distribución probabilística, habitualmente Normal.

Primero veamos las principales diferencias entre los efectos fijos y los efectos aleatorios en un contexto de regresión:

- Los **efectos fijos** se refieren a los parámetros específicos que queremos estimar e interpretar. Por ejemplo, si queremos ver cómo afectan las covariables X_{ijk} a la variable Y_{ij} , los parámetros β_k (con $k = 1, \dots, p$) son efectos fijos. También lo son el *offset*, el intercepto β_0 y los parámetros de la parte temporal.
- Por el contrario, los **efectos aleatorios** se introducen cuando disponemos de observaciones que comparten cierta estructura o jerarquía (en nuestro caso, varios registros de una misma unidad muestral a lo largo del tiempo). En lugar de estimar un coeficiente fijo para cada nivel (unidad muestral), asumimos que dichos niveles proceden de una distribución (comúnmente Normal) con media cero y cierta varianza desconocida que sí se estima. El objetivo es capturar la variabilidad no explicada entre dichos niveles sin tener que estimar un efecto fijo para cada uno (sobrecargando el modelo), es decir, tendríamos que estimar n parámetros más si quisiéramos aplicar efectos fijos.

Así, modelizaremos la variable identificativa de la unidad muestral como un efecto aleatorio para representar la variabilidad que puede haber de una unidad muestral a otra. De esta forma definimos el parámetro u_i como el efecto aleatorio, con $u_i \sim N(0, \sigma^2)$ y estimaremos dicha varianza σ^2 [8].

Finalmente nos quedaría el siguiente NBMM con offset para datos composicionales:

$$\ln(\mu_{ij}) = \ln(N_{ij}) + \beta_0 + \beta_1 x_{ij,1} + \cdots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j + u_i,$$

es decir,

$$\mu_{ij} = N_{ij} \exp \left(\beta_0 + \beta_1 x_{ij,1} + \cdots + \beta_p x_{ij,p} + \beta_{p+1} t'_j + \beta_{p+2} t'^2_j + \beta_{p+3} t'^3_j + u_i \right).$$

Notemos que el efecto aleatorio u_i introduce correlación entre todas las observaciones (i, j) de una misma unidad muestral i . Intuitivamente, si una unidad muestral i tiende a tener un valor de u_i elevado este incremento se refleja en todas sus observaciones a lo largo del tiempo, incluyendo esta variación en el intercepto β_{0k} de nuestro modelo.

CONTEO DE MUERTES EN EUROPA

4.1 Datos de mortalidad en Europa

En este capítulo realizaremos un análisis exploratorio de los datos que hemos recopilado en el archivo `causas_muerte.xls`, a partir de información obtenida del [sitio web de la Organización Mundial de la Salud \(OMS\)](#). El código del análisis se puede encontrar en el repositorio de Github [9]. La tabla de datos contiene información anual sobre las principales causas de muerte en 200 países del mundo desde el año 1990 hasta el 2019, así como algunas covariables.

En el ámbito de la salud pública, resulta esencial identificar patrones y tendencias en el número de muertes por diferentes causas en Europa. El análisis de los conteos de defunciones, según la clasificación de la OMS, proporciona un soporte técnico para el diseño de políticas de prevención y la asignación eficiente de recursos. A grandes rasgos, el análisis de estos datos composicionales (número de muertes o tasa de mortalidad respecto al total de fallecimientos) tiene las siguientes motivaciones:

- **Identificar grupos de riesgo o poblaciones vulnerables:** saber en qué países o regiones determinadas enfermedades cobran mayor relevancia ayuda a planificar intervenciones médicas y estrategias de seguimiento.
- **Asignar recursos médicos de manera eficiente:** la detección de tendencias al alza en enfermedades concretas permite focalizar los esfuerzos en equipamiento, personal sanitario o infraestructuras clave.
- **Planificar campañas de prevención y programas de vacunación:** conocer las causas de mortalidad predominantes respalda la toma de decisiones sobre el contenido y la localización de campañas informativas, además de orientar políticas de vacunación o control de epidemias.

4. CONTEO DE MUERTES EN EUROPA

- **Evaluar la heterogeneidad geográfica y temporal:** los datos comprenden múltiples años y diversos países, lo que exige modelos estadísticos que incorporen efectos mixtos y permitan capturar las diferencias intrínsecas entre regiones.

Con esta perspectiva, el número de muertes debe modelizarse de manera más precisa a través de modelos lineales generalizados mixtos, como la regresión binomial negativa con efecto aleatorio por país. La metodología propuesta en este capítulo busca, en última instancia, la comprensión de los patrones de mortalidad en Europa y ofrecer evidencia útil para el diseño de políticas de salud, el control de enfermedades y la asignación de recursos en programas epidemiológicos y sanitarios a nivel comunitario.

4.1.1 Descripción del conjunto de datos

En la Tabla 4.1 mostramos las variables utilizadas en el análisis.

Nombre de la variable	Descripción de la variable
<i>pais</i>	país del que proceden los datos. En total recoge 200 países.
<i>codigo_Pais</i>	código de tres letras para los nombres de los países según la norma ISO 3166-1 alfa-3.
<i>año</i>	año en el que se recogen los datos. Todos los países tienen datos en todos los años.
<i>poblacion</i>	número de habitantes.
<i>total_muertes</i>	número total de muertes. Calculado como la suma de todas las causas de muerte.
<i>pib</i>	producto interior bruto en millones de dólares. Expresa el valor monetario de la producción de bienes y servicios de demanda final.
<i>idh</i>	índice de desarrollo humano. Se calcula en base a la esperanza de vida, el nivel de educación y el ingreso per cápita.
<i>esperanza_vida_m</i>	esperanza de vida de las mujeres en años.
<i>esperanza_vida_h</i>	esperanza de vida de los hombres en años.
<i>esperanza_vida</i>	esperanza de vida de la población en años.
<i>emisiones_CO2</i>	cantidad de CO ₂ emitido en millones de toneladas.
<i>emisiones_CO2_PIB</i>	cantidad de CO ₂ emitido por cada mil dólares de PIB en kilogramos.
<i>emisiones_CO2_per_capita</i>	cantidad de CO ₂ emitido per cápita en toneladas.

Cuadro 4.1: Variables del conjunto de datos

Además de las variables recogidas en la tabla anterior, disponemos de la desagregación del total de defunciones en función de distintas enfermedades. Específicamente, las variables *meningitis*, *alzheimer*, *parkinson*, *def_nutricionales*, *malaria*, *ahogo*, *violencia_inter*, *trastornos_maternos*, *VIH*, *trastornos_cons_drogas*, *tuberculosis*, *enf_cardiovasculares*, *infecciones_respi*, *trastornos_neonatales*, *trastornos_Cons_alcohol*, *autolesiones*, *exp_fuer_naturaleza*, *enf_diarreicas*, *exp_amb_temperatura*, *neoplasias*,

conflicto_terrorismo, *diabetes_mellitus*, *enfermedad_crónica*, *envenenamientos*, *desnutrición_energetica*, *lesiones_carretera*, *enfermedades_cronicas*, *cirrosis_crónicas*, *enfermedades_digestivas*, *fuego_calientes* y *hepatitis_aguda* registran el número de muertes atribuidas a la causa correspondiente indicada en el nombre de cada variable.

4.2 Procesamiento de datos para el análisis

En esta sección mostramos las transformaciones realizadas a la base de datos con el objetivo de mejorar el posterior análisis. Estas incluyen la reducción de países, la agrupación de causas de muerte y la eliminación de algunas covariables.

Primero de todo, nos restringiremos a los datos que nos proporcionan los países europeos para así reducir el número de unidades muestrales y centrarnos en el objetivo del trabajo.

Ahora, veamos en la Figura 4.1 la distribución temporal de la cantidad de defunciones por cada causa mediante gráficos de cajas, ordenados de mayor a menor cantidad de fallecimientos. Es decir, cada caja tiene como datos las muertes totales por esa causa en cada año.




Figura 4.1: Boxplots del conteo anual de muertes totales, en escala logarítmica y ordenados en orden descendente según la mediana.

En este gráfico podemos ver grandes diferencias en el conteo de las causas. Esto se puede apreciar gracias a la escala logarítmica. Mientras que los conteos de defunciones

4. CONTEO DE MUERTES EN EUROPA

por malaria se encuentran alrededor de 10, los conteos de muertes por enfermedades cardiovasculares se encuentran alrededor de medio millón. Los colores de las cajas determinan en qué agrupación se encuentran.

En la Figura 4.2 se muestra el número de defunciones totales por cada causa de muerte, también ordenada de mayor a menor cantidad de fallecimientos.

	Causa	Total_muertes		Causa	Total_muertes
1	enf_cardiovasculares	112879395	16	tuberculosis	1185277
2	neoplasias	52021539	17	ahogo	983800
3	enfermedades_digestivas	10391105	18	exp_amb_temperatura	887526
4	enfermedades_cronicas	9745923	19	VIH	789559
5	alzheimer	7467599	20	fuego_calientes	676362
6	infecciones_respi	6629810	21	trastornos_cons_drogas	570498
7	cirrosis_crónicas	5280017	22	envenenamientos	531265
8	autolesiones	4577746	23	enf_diarreicas	325159
9	diabetes_mellitus	3803380	24	def_nutricionales	226642
10	lesiones_carretera	3395984	25	meningitis	209458
11	enfermedad_crónica	3046971	26	desnutrición_energetica	180132
12	trastornos_Cons_alcohol	2197986	27	conflicto_terrorismo	155817
13	violencia_inter	1862264	28	trastornos_maternos	61378
14	parkinson	1657290	29	hepatitis_aguda	47408
15	trastornos_neonatales	1591316	30	exp_fuer_naturaleza	31464
			31	malaria	228

Figura 4.2: Conteo de muertes totales ordenado en orden descendente.

Aquí podemos ver el conteo exacto de cada causa durante todo el intervalo temporal y se puede apreciar con más claridad que hay algunas causas que apenas causan impacto. Observemos que en este tiempo la malaria solo registra 228 defunciones, mientras que enfermedades cardiovasculares registra más de cien millones. Por ello, con el objetivo de reducir dimensionalidad y manejar adecuadamente estas diferencias, vamos a agrupar las causas siguiendo el criterio de la OMS en [este enlace](#). Los grupos que nos quedan son los siguientes:

- Enfermedades infecciosas o parasitarias (*enf_infec_paras*). En este grupo incluimos *meningitis*, *malaria*, *VIH* y *tuberculosis*; color naranja en el gráfico 4.1.
- Enfermedades del sistema nervioso (*enf_sist_nervioso*). En este grupo incluimos *alzheimer* y *parkinson*; color azul en el gráfico 4.1.
- Enfermedades endocrinas, nutricionales o metabólicas (*enf_metabolicas*). En este grupo incluimos *def_nutricionales*, *diabetes_mellitus* y *desnutrición_energetica*; color amarillo en el gráfico 4.1.
- Causas externas de morbilidad o mortalidad, lesiones y envenenamientos (*causas_externas*). En este grupo incluimos *ahogo*, *violencia_inter*, *autolesiones*, *exp_fuer_naturaleza*, *conflicto_terrorismo*, *lesiones_carretera*, *exp_amb_temperatura*, *envenenamientos* y *fuego_calientes*; color púrpura en el gráfico 4.1.

- Causas relacionadas con el embarazo, parto o puerperio (en la madre) y afecciones en el periodo perinatal (en el hijo) (*trastornos_embarazo*). En este grupo incluimos *trastornos_maternos* y *trastornos_neonatales*; color oliva en el gráfico 4.1.
- Trastornos mentales, del comportamiento o del desarrollo neurológico (*trastornos_mentales*). En este grupo incluimos *trastornos_cons_drogas* y *trastornos_cons_alcohol*; color magenta en el gráfico 4.1.
- Enfermedades del sistema circulatorio (*enf_cardiovasculares*). En este grupo incluimos *enf_cardiovasculares*; color rojo en el gráfico 4.1.
- Enfermedades del sistema respiratorio (*infecciones_respi*). En este grupo incluimos *infecciones_respi*; color cian en el gráfico 4.1.
- Enfermedades del sistema digestivo (*enf_sist_digestivo*). En este grupo incluimos *enf_diarreicas*, *cirrosis_crónicas*, *enfermedades_digestivas* y *hepatitis_aguda*; color marrón en el gráfico 4.1.
- Neoplasias (*neoplasias*). En este grupo incluimos *neoplasias*; color verde en el gráfico 4.1.
- Enfermedades crónicas (*enf_cronicas*). En este grupo incluimos *enfermedad_crónica* y *enfermedades_cronicas*; color lima en el gráfico 4.1.




Figura 4.3: Boxplots del conteo anual de muertes totales agrupadas y ordenadas en orden descendente según la mediana.

4. CONTEO DE MUERTES EN EUROPA

Una vez agrupadas las causas de muerte, en la Figura 4.3 se muestran los boxplots resultantes de los conteos de muertes totales. De nuevo, apreciamos grandes diferencias entre la causa con más conteos (enfermedades cardiovasculares) y la causa con menos conteos (trastornos del embarazo). Sin embargo, esta última ya tiene un conteo mayor que en el anterior gráfico, con decenas de miles de defunciones. Y con este agrupamiento, la Figura 4.4 muestra el número total de fallecimientos por cada causa de la nueva agrupación.

	Causa	Total_muertes
1	enf_cardiovasculares	112879395
2	neoplasias	52021539
3	enf_sist_digestivo	16043689
4	causas_externas	13102228
5	enf_cronicas	12792894

	Causa	Total_muertes
6	enf_sist_nervioso	9124889
7	infecciones_respi	6629810
8	enf_metabolicas	4210154
9	trastornos_mentales	2768484
10	enf_infec_paras	2184522
11	trastornos_embarazo	1652694

Figura 4.4: Conteo de muertes totales ordenado en orden descendente.

De nuevo, podemos ver el conteo exacto de cada causa ordenado también de mayor a menor. Se puede apreciar que después de la agrupación, la causa con menos muertes en todo este tiempo ya contempla más de un millón de conteos, con lo que hemos reducido las diferencias.

Por último, recordemos que tenemos las siguientes covariables: *poblacion*, *pib*, *idh*, *esperanza_vida_m*, *esperanza_vida_h*, *esperanza_vida*, *emisiones_CO2*, *emisiones_CO2_PIB* y *emisiones_CO2_per_capita*. Esta son variables que nos proporcionan información que nos puede ayudar a describir las variables objetivo, en nuestro caso, las causas de muerte. Sin embargo, notemos que nos proporcionan información redundante: el IDH se calcula a partir del PIB y de la esperanza de vida, así que podríamos prescindir de estas variables. Por otro lado, cuanto más población tenga un país, más emisiones de CO₂ habrá, por lo que tampoco hace falta utilizar como covariable a *emisiones_CO2*. En efecto, podemos ver las altas correlaciones que tienen las variables entre sí en la matriz de correlaciones mostrada en la Figura 4.5.

En el gráfico 4.5 podemos ver efectivamente que *idh* está altamente correlacionado con las variables relacionadas con la esperanza de vida. También vemos una alta correlación entre *poblacion* y *emisiones_CO2*. Sin embargo, la correlación entre *idh* y *pib* no es tan alta, pero esto es debido a que el IDH se calcula a partir del logaritmo del PIB, por lo que no tienen alta correlación lineal.

De esta forma, consideraremos únicamente las covariables *poblacion*, *idh*, *emisiones_CO2_PIB* y *emisiones_CO2_per_capita* en la base de datos.

Después de aplicar las transformaciones explicadas en esta sección, obtenemos la base de datos final con la que vamos a trabajar. En la tabla 4.2 mostramos los datos que nos ofrecen las cinco primeras mediciones de esta base de datos.




Figura 4.5: Matriz de correlaciones de las covariables. Tonos azules indican correlación positiva y tonos rojos correlación negativa.

4.3 Tratamiento de datos composicionales

Las variables que nos dan información sobre las causas de fallecimiento tienen naturaleza composicional, ya que todas las entradas son positivas (son conteos de defunciones); y la única información relevante en cada fila (país-año) es la relación entre las componentes, ya que esta nos da el porcentaje de muertes por cada causa.

Antes de poder aplicar técnicas de análisis de datos composicionales hay que preprocesar los datos siguiendo los pasos explicados en [10, 5], que son imputación de ceros y transformación logarítmica.

4.3.1 Imputación de ceros

Hay varias estrategias para imputar ceros. Primero, nos interesa saber cuántos conteos de ceros hay en cada variable, es decir, en cuántas mediciones (país-año) no ha habido muertes por esa causa, estos conteos son mostrados en la Tabla 4.3.

En total hay 56 ceros, que de un total de 15180 entradas, supone un 0,3689 %. Solo se muestra trastornos del embarazo y mentales, porque el resto de las causas analizadas no presenta conteos iguales a cero. Como el porcentaje es menor a 10 %, seguimos el método más sencillo que consiste en sustituir los ceros por una cantidad fija de 0,65 tal como lo sugieren en [10].

4.3.2 Transformación CLR

Recordemos que un vector de datos composicionales $\mathbf{x} = (x_1, \dots, x_n)$ tiene componentes positivas y suma un total constante. Por lo tanto, estos datos no viven en todo $\mathbb{R}^n$,

4. CONTEO DE MUERTES EN EUROPA

<i>pais</i>	Albania	Albania	Albania	Albania	Albania
<i>codigo_Pais</i>	ALB	ALB	ALB	ALB	ALB
<i>año</i>	1990	1991	1992	1993	1994
<i>poblacion</i>	3295066	3302082	3303739	3300711	3293999
<i>enf_infec_paras</i>	154	158	149	139	126
<i>enf_sist_nervioso</i>	453	459	459	460	463
<i>enf_metabolicas</i>	172	189	192	194	192
<i>causas_externas</i>	893	979	987	963	949
<i>trastornos_embarazo</i>	897	887	870	858	847
<i>trastornos_mentales</i>	15	18	18	21	27
<i>enf_cardiovasculares</i>	6701	6903	6699	6480	6191
<i>infecciones_respi</i>	2140	2196	2104	1977	1795
<i>enf_sist_digestivo</i>	1054	1071	1038	997	945
<i>neoplasias</i>	2616	2698	2642	2586	2493
<i>enf_cronicas</i>	1247	1255	1200	1144	1064
<i>total_muertes</i>	16342	16813	16358	15819	15092
<i>idh</i>	64.7	62.9	61.4	61.7	62.4
<i>emisiones_CO2_PIB</i>	0.42	0.39	0.23	0.20	0.19
<i>emisiones_CO2_per_capita</i>	2.03	1.35	0.75	0.71	0.76

Cuadro 4.2: Base de datos final luego de aplicar el preprocesamiento explicado en esta sección.

Nombre de la variable	Nº ceros
<i>trastornos_embarazo</i>	26
<i>trastornos_mentales</i>	30

Cuadro 4.3: Número de conteos iguales a cero para cada causa de fallecimiento.

sino en un subespacio restringido conocido como el simplex:

$$\mathcal{S}^n = \left\{ (x_1, \dots, x_n) \in \mathbb{R}^n \left| \sum_{i=1}^n x_i = \kappa; x_i > 0, \forall i = 1, \dots, n \right. \right\}.$$

Esta restricción implica que las componentes no son independientes entre sí —un aumento en una parte debe compensarse con una disminución en otra— y esto viola supuestos básicos como la independencia o la homocedasticidad que subyacen a técnicas como la regresión lineal u otras basadas en la estadística clásica.

Para solventar este problema, podemos aplicar un isomorfismo entre el simplex y un espacio euclídeo tradicional. Hay tres isomorfismos bien caracterizados que transforman el simplex al espacio real:

1. Transformación log-ratio aditiva (ALR, por sus siglas en inglés) es un isomorfismo donde $\text{alr}: S^n \rightarrow \mathbb{R}^{n-1}$ viene dado por

$$\text{alr}(\mathbf{x}) = \left(\ln\left(\frac{x_1}{x_n}\right), \dots, \ln\left(\frac{x_{n-1}}{x_n}\right) \right).$$

2. Transformación log-ratio centrada (CLR, por sus siglas en inglés) es una isometría donde $\text{clr}: S^n \rightarrow U$, con $U = \{(y_1, \dots, y_n) \in \mathbb{R}^n \mid \sum_{i=1}^n y_i = 0\} \subset \mathbb{R}^n$, viene dado por

$$\text{clr}(\mathbf{x}) = \left(\ln\left(\frac{x_1}{g(\mathbf{x})}\right), \dots, \ln\left(\frac{x_{n-1}}{g(\mathbf{x})}\right) \right),$$

donde $g(\mathbf{x})$ es la media geométrica de $\mathbf{x}$, es decir,

$$g(\mathbf{x}) = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}.$$

3. Transformación log-ratio isométrica (ILR, por sus siglas en inglés) es una isometría donde $\text{ilr}: S^n \rightarrow \mathbb{R}^{n-1}$ viene dado por

$$\text{ilr}(\mathbf{x}) = (\langle \mathbf{x}, \mathbf{e}_1 \rangle, \dots, \langle \mathbf{x}, \mathbf{e}_{n-1} \rangle),$$

donde $\{\mathbf{e}_1, \dots, \mathbf{e}_{n-1}\}$ es una base ortonormal del simplex.

Cada una de ellas tiene sus ventajas y desventajas. Nosotros utilizaremos la transformación CLR, donde cada coordenada transformada representa el logaritmo de la razón de cada componente respecto a la media geométrica de todas las partes. Esto significa que no se interpretan valores absolutos, sino desviaciones relativas: un valor CLR positivo indica que la parte correspondiente es mayor que la media geométrica de la composición, mientras que un valor negativo indica que es menor. Una vez aplicada esta transformación en las variables con naturaleza composicional (las causas de muerte), mostramos el resultado de las cuatro primeras mediciones en la Tabla 4.4 [11].

4.4 Matriz de correlaciones

Analicemos la matriz de correlaciones de Spearman mostrada en la Figura 4.6, de las causas de muerte y las covariables. Utilizamos la correlación de Spearman, en lugar de la de Pearson, ya que nuestras variables de interés —las causas de muerte— son de naturaleza discreta y pueden no cumplir los supuestos de normalidad y linealidad.

Examinar esta matriz es fundamental porque nos permite identificar relaciones potenciales de asociación entre diferentes causas de mortalidad y factores socioeconómicos o ambientales, como las emisiones de CO₂ o el IDH. Detectar correlaciones altas o patrones inusuales puede orientar el planteamiento de modelos explicativos más robustos, ayudar a evitar la multicolinealidad y aportar hipótesis plausibles sobre interacciones o factores comunes que afecten simultáneamente a varias causas de muerte.

Fijémonos primero en las correlaciones entre causas de defunción y covariables. Las variables *poblacion* y *emisiones_CO2_per_capita* apenas tienen correlación con las

4. CONTEO DE MUERTES EN EUROPA

<i>pais</i>	Albania	Albania	Albania	<i>Albania</i>
<i>codigo_Pais</i>	ALB	ALB	ALB	ALB
<i>año</i>	1990	1991	1992	1993
<i>poblacion</i>	3295066	3302082	3303739	3300711
<i>enf_infec_paras</i>	-1.421125	-1.441382	-1.479668	-1.535840
<i>enf_sist_nervioso</i>	-0.3421852	-0.3749270	-0.3545639	-0.3390876
<i>enf_metabolicas</i>	-1.310583	-1.262230	-1.226119	-1.202456
<i>causas_externas</i>	0.3365093	0.3825544	0.4110559	0.3997394
<i>trastornos_embarazo</i>	0.3409786	0.2838677	0.2848791	0.2842900
<i>trastornos_mentales</i>	-3.750027	-3.613605	-3.593242	-3.425792
<i>enf_cardiovasculares</i>	2.351935	2.335734	2.326099	2.306162
<i>infecciones_respi</i>	1.210484	1.190416	1.167981	1.119022
<i>enf_sist_digestivo</i>	0.5022704	0.4723708	0.4614369	0.4344367
<i>neoplasias</i>	1.411324	1.396289	1.395677	1.387554
<i>enf_cronicas</i>	0.6704186	0.6309136	0.6064627	0.5719721
<i>total_muertes</i>	16342	16813	16358	15819
<i>idh</i>	64.7	62.9	61.4	61.7
<i>emisiones_CO2_PIB</i>	0.42	0.39	0.23	0.20
<i>emisiones_CO2_per_capita</i>	2.03	1.35	0.75	0.71

Cuadro 4.4: Base de datos obtenida a partir de la base mostrada en la Tabla 4.2 con transformación CLR

causas de muerte. La variable *emisiones_CO2_PIB* tiene correlaciones más altas: las más significativas son con *enf_sist_nervioso* y *causas_externas*. Por otro lado, la variable *idh* presenta altas correlaciones con algunas causas, tanto positivamente como negativamente. Esto es debido a que un IDH bajo corresponde a países poco desarrollados y podemos ver en las correlaciones negativas enfermedades que suelen ser comunes en estos países: enfermedades infecciosas o parasitarias, las cuales recordemos que engloban a meningitis, malaria, VIH y tuberculosis; y trastornos del embarazo, los cuales engloban trastornos maternos y neonatales. Luego, en las correlaciones positivas, podemos ver enfermedades del sistema nervioso, que engloba alzheimer y parkinson; neoplasias y enfermedades crónicas.

Por último, vemos que hay algunas enfermedades bastante correlacionadas y otras que no. La correlación positiva que más destaca es entre enfermedades del sistema nervioso y neoplasias, con un valor de 0,82; mientras que la correlación negativa más destacada es entre enfermedades del sistema nervioso y trastornos del embarazo, con un valor de $-0,72$. La correlación más pequeña en valor absoluto, con un valor de 0, corresponde a enfermedades metabólicas con infecciones respiratorias.

Cabe destacar el caso de la variable *total_muertes* que no tiene ninguna correlación

4.4. Matriz de correlaciones




Figura 4.6: Matriz de correlaciones de Spearman entre los conteos de muertes y las covariables de la base.

considerable exceptuando con población, la cual es obvia.

año	1990	1991	1992	1993	1994
<i>enf_infec_paras</i>	60594	63604	68723	78164	87625
<i>enf_sist_nervioso</i>	203318	210386	216637	223731	229549
<i>enf_metabolicas</i>	120422	122416	123916	126732	128387
<i>causas_externas</i>	443676	463734	504519	551287	582808
<i>trastornos_embarazo</i>	107599	101728	94695	89298	85891
<i>trastornos_mentales</i>	63639	69365	78402	90635	99876
<i>enf_cardiovasculares</i>	3511347	3567511	3656760	3872094	3996749
<i>infecciones_respi</i>	218396	215852	217936	228723	233884
<i>enf_sist_digestivo</i>	429695	436562	448848	471906	490331
<i>neoplasias</i>	1550681	1572939	1604179	1660453	1687884
<i>enf_cronicas</i>	404001	406141	410952	425140	430979

Cuadro 4.5: Estructura de la tabla de datos de defunciones por año y covariables mostradas mediante la instrucción `str` de R.

4. CONTEO DE MUERTES EN EUROPA




Figura 4.7: Conteos totales por año de muertes por enfermedades infecciosas o parasitarias




Figura 4.8: Conteos totales por año de muertes por causas externas de morbilidad o mortalidad, lesiones y envenenamientos

4.5 Tendencias temporales

En esta sección vamos a estudiar las tendencias temporales de cada causa de muerte. Para ello, vamos a trabajar con una base de datos resultante de sumar los conteos de todos los países, es decir, vamos a ver la evolución temporal de cada causa a nivel europeo. La estructura de la base de datos es mostrada en la Tabla 4.5.

En la Figura 4.7 se muestra la evolución temporal totales por año de muertes por enfermedades infecciosas o parasitarias, y análogamente, para causas externas de morbilidad o mortalidad, lesiones y envenenamientos en la Figura 4.8.

En estas figuras vemos un comportamiento alcista durante los primeros años hasta alcanzar sus máximos alrededor de 1995, para luego seguir con un comportamiento bajista y acabar en 2019 con una cantidad inferior a la cantidad de muertes iniciales, aunque este comportamiento en la Figura 4.8 es bastante más inferior que en la Figura 4.7.

En las figuras 4.9 a 4.13, podemos ver una clara tendencia alcista del número de muertes. Sin embargo, las defunciones por enfermedades del sistema digestivo se han estabilizado entre 550000 y 600000 a partir de 2005, y en las defunciones por enfermedades crónicas tenemos la tendencia alcista a partir de 2006.

En la Figura 4.14 podemos apreciar una clara tendencia bajista, siendo la cantidad de muertes de 2019 más de un 75 % inferior a la cantidad de 1990.

En las figura 4.15 a 4.17 se observa un comportamiento sinusoidal, con tendencias alcistas y bajistas en diferentes ventanas temporales. Las primeras dos causas tienen su mínimo en 1990, mientras que la tercera lo tiene en 2011. Por otro lado, el máximo de la primera lo alcanza en 2005, la segunda en 2003 y la tercera en 1995.

Por último, veamos la evolución de todas las causas de muerte agrupadas de acuerdo al número medio de muertes: En la Figura 4.18 están las muertes cuyos conteos se consideran bajos (entre 20 000 y 170 000), en la Figura 4.19 medios (entre 200 000 y 600 000), y en la Figura 4.20 los que se consideran altos (entre 1 550 000 y 4 020 000).




Figura 4.9: Conteos totales por año de muertes por enfermedades del sistema nervioso




Figura 4.10: Conteos totales por año de muertes por enfermedades endocrinas, nutricionales o metabólicas




Figura 4.11: Conteos totales por año de muertes por enfermedades del sistema digestivo




Figura 4.12: Conteos totales por año de muertes por neoplasias




Figura 4.13: Conteos totales por año de muertes por enfermedades crónicas




Figura 4.14: Conteos totales por año de muertes por causas relacionadas con el embarazo, parto o puerperio y afecciones en el periodo perinatal

4. CONTEO DE MUERTES EN EUROPA




Figura 4.15: Conteos totales por año de muertes por trastornos mentales, del comportamiento o del desarrollo neurológico




Figura 4.16: Conteos totales por año de muertes por enfermedades del sistema circulatorio




Figura 4.17: Conteos totales por año de muertes por enfermedades del sistema respiratorio




Figura 4.18: Evolución temporal de las causas con número de muertes bajo (entre 20 000 y 170 000)

4.5. Tendencias temporales




Figura 4.19: Evolución temporal de las causas con número de muertes medio (entre 200 000 y 600 000)




Figura 4.20: Evolución temporal de las causas con número de muertes alto (entre 1 550 000 y 4 020 000)

4.6 Análisis en componentes principales

En esta sección se presenta un Análisis en Componentes Principales (ACP), una técnica estadística que permite reducir la dimensión de los datos y visualizar sus patrones de variabilidad conservando la mayor cantidad de información posible. Exploraremos en detalle las medianas temporales para cada país. Además, en el Anexo A.1 se incluyen los gráficos de los ACP realizados exclusivamente con los datos de 1990 y 2019, correspondientes al inicio y final del periodo analizado. El objetivo principal es observar si se producen cambios significativos en los patrones de agrupación entre países a lo largo del tiempo.

Este análisis se basa en una base de datos construida a partir de la mediana temporal de cada causa de muerte y del IDH por país. Durante la elaboración de la base de datos se identificaron dos valores nulos (0), que fueron imputados con el valor 0,65 para poder aplicar la transformación CLR. Tras esta transformación, los datos fueron centrados para llevar a cabo el ACP.

En la matriz de varianzas-covarianzas observamos que las varianzas oscilan entre 0,0788 (para *enf_sist_digestivo*) y 0,7237 (para *trastornos_mentales*). Esta diferencia justifica la necesidad de escalar las variables antes de aplicar el ACP, ya que, en caso contrario, las componentes principales estarían dominadas por las variables con mayor varianza.

En la Figura 4.21 se muestra la matriz de correlaciones de Pearson basada en las medianas temporales por país.




Figura 4.21: Matriz de correlaciones de Pearson calculada a partir de las medianas temporales por país.

La correlación positiva más fuerte se observa entre *enf_sist_nervioso* y *neoplasias* ($r = 0,76$), mientras que la más negativa se da entre *causas_externas* y *enf_cronicas* ($r = -0,66$).

El ACP revela que las dos primeras componentes principales explican conjuntamente alrededor del 61 % de la variabilidad total, como se muestra en la Figura 4.22.




Figura 4.22: Porcentaje de varianza explicada por cada componente principal a partir de las medianas temporales por país.

A partir de la cuarta componente, el incremento en la varianza explicada es marginal, por lo que es razonable trabajar con dos o tres componentes. El círculo de correlaciones (Figura 4.23) permite visualizar las relaciones entre variables y su representación en el plano principal.




Figura 4.23: Círculo de correlaciones del ACP calculado a partir de las medianas temporales por país.

La mayoría de las variables están bien representadas en el plano principal, con excepción de *enf_cardiovasculares* y *enf_sist_digestivo*, que muestran una menor contribu-

4. CONTEO DE MUERTES EN EUROPA

ción. Las Figuras 4.24 y 4.25 muestran, respectivamente, las contribuciones individuales de las variables y su calidad de representación en el plano.




Figura 4.24: Contribuciones de cada variable al plano principal del ACP.




Figura 4.25: Calidad de representación ($\cos^2$) en el plano principal del ACP.

Finalmente, en la Figura 4.26 se presenta un biplot con la posición de cada país en el plano principal, coloreados según su IDH, dividido por cuartiles.




Figura 4.26: Representación de los países en el plano principal del ACP, coloreados según su IDH.

El gráfico muestra una clara estructura de agrupamiento según el nivel de desarrollo. Los países con mayor IDH se ubican principalmente en el tercer cuadrante, asociado a causas de muerte propias de contextos más desarrollados (como enfermedades del sistema nervioso y neoplasias). Por el contrario, los países con menor IDH se concentran en el primer cuadrante, caracterizado por enfermedades infecciosas y trastornos relacionados con el embarazo.

Este análisis exploratorio ha permitido identificar patrones relevantes en la distribución de las causas de muerte y su asociación con el nivel de desarrollo de los países. La estructura observada en el ACP sugiere que el IDH actúa como un eje organizador de los perfiles epidemiológicos nacionales. No obstante, para cuantificar de manera más precisa la relación entre las causas de muerte y variables explicativas como el IDH, resulta necesario utilizar un modelo estadístico adaptado al conteo de datos y a la posible sobredispersión. En la siguiente sección, se aplicará un modelo de regresión binomial negativa sobre el número total de muertes por país.

4.7 Ajuste del Modelo Binomial Negativo con Efectos Mixtos y *offset*

Para finalizar, en esta sección abordamos el ajuste del NBMM propuesto en la sección 3.4 para analizar el conteo de muertes en Europa. Antes de entrar en detalles, conviene justificar por qué utilizamos un modelo Binomial Negativo en lugar de uno Poisson, que suele ser el más usual para modelizar datos de conteo.

4.7.1 Motivación para usar un modelo Binomial Negativo

Como dijimos en la introducción del capítulo anterior, los modelos de regresión Poisson se aplican en conjuntos de datos de conteo equidispersos ($E[Y] = \text{Var}(Y)$). Sin embargo, esto no ocurre en nuestra base de datos.

Para ilustrar intuitivamente este fenómeno, podríamos tomar los datos de un país concreto (por ejemplo, España) sobre muertes causadas por enfermedades del sistema nervioso entre 1990 y 2019. Si agrupáramos esos valores y tratáramos de calcular una media y varianza global, obtendríamos $\hat{\mu} = 26381,7$ y $\hat{\sigma}^2 = 44076945$, donde claramente $\hat{\sigma}^2 \gg \hat{\mu}$. Aunque esta comparación numérica es meramente orientativa, puesto que cada año está asociado a diferentes variables aleatorias, sirve para ver que probablemente tendremos sobredispersión. Esto haría que el modelo Poisson:

- Subestime sistemáticamente la probabilidad de observar años con conteos muy altos.
- Proporcione intervalos de confianza demasiado estrechos para los parámetros.

Por eso, elegimos la regresión Binomial Negativa para nuestro conjunto de datos. Recordemos que en este modelo la varianza cumple:

$$\text{Var}(Y) = E[Y] + \alpha (E[Y])^2,$$

siendo $\alpha > 0$ el parámetro de sobredispersión. Más adelante, cuando ajustemos el modelo veremos rigurosamente que:

- Si $\alpha \approx 0$, los datos se comportan aproximadamente como equidispersos.
- Si α es significativamente mayor que cero, es señal de sobredispersión en el conteo de muertes.

De esta manera, el parámetro α nos permitirá cuantificar la sobredispersión real de los datos, sin necesidad de depender de una media y varianza muestral imposibles de calcular en cada país-año.

4.7.2 Descripción del modelo propuesto

Basándonos en la motivación anterior, proponemos el NBMM descrito en la sección 3.4. Modelaremos la variable que representa las muertes causadas por las enfermedades del sistema nervioso. El resto de causas se realizan de manera análoga.

Sea Y_{ij} la variable aleatoria que representa el conteo de muertes causadas por las enfermedades del sistema nervioso en el país i y el año j . Por ejemplo, $y_{41,0} = 14557$ son las defunciones en España ($i = 41$) en el año 1990 ($j = 1$) por esta causa. Supondremos que $Y_{ij} \sim \text{NB}(\mu_{ij}, \alpha)$ y queremos ver cómo afecta el IDH y el tiempo a esta variable, añadiendo un *offset*, por ser datos composicionales, y efectos aleatorios, para capturar la variabilidad entre países. Así, la ecuación de nuestro modelo queda

$$\ln(\mu_{ij}) = \ln(N_{ij}) + \beta_0 + \beta_1 x_{ij} + \beta_2 t_j + \beta_3 t_j^2 + \beta_4 t_j^3 + u_i,$$

es decir,

$$\mu_{ij} = N_{ij} \exp(\beta_0 + \beta_1 x_{ij} + \beta_2 t_j + \beta_3 t_j^2 + \beta_4 t_j^3 + u_i),$$

donde:

- N_{ij} es el numero total de fallecimientos en el país i y el año j .
- x_{ij} es el IDH del país i en el año j .
- t_j es el año reescalado, es decir, $t_j = \frac{j-1}{29}$.
- u_i es el efecto aleatorio por país. Son realizaciones de una variable aleatoria que sigue la distribución $N(0, \sigma^2)$.

4.7.3 Estimación del modelo

Para realizar la estimación, utilizamos la función `glmm.nb` del paquete NBZIMM [5], que permite ajustar modelos de regresión binomial negativa para datos de conteo con sobredispersión. Tal como se comentó anteriormente, aplicamos este modelo específicamente a los casos de muertes por enfermedades del sistema nervioso, dado que este paquete no permite estimar modelos multivariantes de forma conjunta.

Una vez estimado el modelo, empleamos la función `summary()` para examinar los valores estimados de los parámetros y evaluar su significancia estadística. La Tabla 4.6 resume las estimaciones de los coeficientes (β), junto con su error estándar, el valor t y el p -valor asociado para contrastar la hipótesis nula de que cada parámetro es igual a cero.

Cuadro 4.6: Estimación de los parámetros del modelo binomial negativo.

Parámetro	Estimación	Error estándar	<i>t</i> -valor	<i>p</i> -valor
β_0	-3.683567	0.07389994	-49.84533	0.0000
β_1	0.002111	0.00059922	3.52268	0.0004
β_2	0.083668	0.07521046	1.11245	0.2661
β_3	1.081848	0.17606800	6.14449	0.0000
β_4	-0.581503	0.11543809	-5.03736	0.0000

Analizando los resultados, observamos que el intercepto (β_0) es significativamente distinto de cero (p -valor < 0.001), lo que sugiere una tasa de base relevante en el conteo de muertes. Asimismo, los coeficientes β_1 , β_3 y β_4 presentan valores t elevados y p -valores muy bajos, indicando que las covariables correspondientes tienen un efecto estadísticamente significativo sobre la variable respuesta.

En contraste, el coeficiente β_2 , correspondiente a la variable *año*, no resulta significativo (p -valor = 0,2661), por lo que podría considerarse su exclusión o una reinterpretación de su efecto dentro del modelo.

Estos resultados permiten interpretar la magnitud y dirección de los efectos de cada covariable sobre el número de muertes, teniendo en cuenta la naturaleza logarítmica del enlace utilizado en la regresión binomial negativa. La validación del modelo debería completarse mediante un análisis de residuos y la comprobación de los supuestos del modelo, con el fin de garantizar la robustez de las conclusiones obtenidas.

La estimación b_k corresponde al valor calculado por el método de scoring. Este estimador sigue, asintóticamente, una distribución normal con media el parámetro β_k y varianza igual al inverso de la información observada, $\mathfrak{J}_k^{-1}$ (el error estándar al cuadrado). Por lo tanto:

$$\frac{b_k - \beta_k}{\sqrt{\mathfrak{J}_k^{-1}}} \underset{n \rightarrow \infty}{\sim} N(0, 1).$$

Cuando el tamaño muestral no es lo suficientemente grande, esta estadística sigue una distribución t de Student. En nuestro caso, dado que $n = 1380$, se puede aproximar por una distribución normal estándar.

El p -valor asociado corresponde al siguiente contraste de hipótesis:

$$\begin{cases} H_0 : \beta_k = 0, \\ H_1 : \beta_k \neq 0. \end{cases}$$

El valor z (denominado t en la tabla) se calcula como:

$$z_k = \frac{b_k - 0}{\sqrt{\mathfrak{J}_k^{-1}}},$$

y el p -valor se obtiene como:

$$p_k = 2 \cdot P(Z \geq |z_k|), \quad \text{con } Z \sim N(0, 1).$$

4. CONTEO DE MUERTES EN EUROPA

Utilizamos un nivel de significación del 5%: si $p_k < 0,05$, se rechaza la hipótesis nula y se concluye que el coeficiente β_k es significativamente distinto de cero.

Como se puede ver, todos los coeficientes excepto β_2 son estadísticamente significativos. En el caso de β_2 , con un p -valor del 26,61 %, no se puede rechazar la hipótesis nula. Por tanto, planteamos la posibilidad de eliminar esta covariable del modelo y comparar ambas versiones.

A continuación, presentamos los resultados de un segundo modelo, en el que se ha excluido la variable correspondiente a β_2 :

Cuadro 4.7: Estimación del modelo sin la covariable no significativa.

Parámetro	Estimación	Error estándar	t -valor	p -valor
β_0	-3.678163	0.07366921	-49.92810	0.0000
β_1	0.002147	0.00059746	3.59387	0.0003
β_3	1.268723	0.05209944	24.35196	0.0000
β_4	-0.696646	0.05076545	-13.72284	0.0000

Para comparar estos dos modelos calculamos la diferencia de devianzas ΔD como estadístico de bondad de ajuste. Sea M_0 el modelo reducido (sin β_2), con hipótesis:

$$H_0 : \boldsymbol{\beta} = (\beta_0, \beta_1, \beta_3, \beta_4)^\top,$$

y M_1 el modelo completo, que incluye la covariable correspondiente a β_2 , con hipótesis:

$$H_1 : \boldsymbol{\beta} = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4)^\top.$$

Las devianzas de ambos modelos, comparadas con el modelo saturado (que toma $\mu_{ij} = y_{ij}$), son:

- $D_0 = 440,2696$, con $D_0 \sim \chi^2(1331)$, y p -valor: $P(\chi^2_{1331} \geq D_0) = 1$.
- $D_1 = 439,9582$, con $D_1 \sim \chi^2(1330)$, y p -valor: $P(\chi^2_{1330} \geq D_1) = 1$.

Ambos modelos se ajustan de forma similar al modelo saturado. La diferencia de devianzas es:

$$\Delta D = D_0 - D_1 = 0,3114133,$$

y dado que $\Delta D \sim \chi^2(1)$, su p -valor asociado es:

$$P(\chi^2_1 \geq \Delta D) = 0,5768142.$$

Este resultado indica que no existe evidencia suficiente para preferir el modelo completo sobre el modelo reducido. Por tanto, optamos por el modelo más simple (M_0) por razones de parsimonia.

Finalmente, el valor estimado del parámetro de sobredispersión es $\alpha = 0,9977562$, lo cual confirma que los datos presentan sobredispersión y justifica el uso del modelo

binomial negativo frente a una regresión de Poisson estándar. Además, podemos ver que la desviación típica del efecto aleatorio u_i es 0,4029578 y en la Tabla 4.8 vemos los valores que toma en los diferentes países.

Albania	0.0219	Andorra	0.3732	Armenia	-0.4616
Austria	0.3099	Azerbaiyán	-0.8298	Bélgica	0.3373
Bielorrusia	-0.3706	Bos-Herz	-0.2554	Bulgaria	-0.4308
Chipre	-0.0471	Croacia	-0.0874	Dinamarca	0.2052
Eslovaquia	-0.1458	Eslovenia	0.2455	España	0.5959
Estonia	-0.1505	Finlandia	0.2985	Francia	0.5594
Georgia	-0.2092	Grecia	0.2051	Hungría	-0.2352
Irlanda	0.1761	Islandia	0.5425	Italia	0.4792
Kazajistán	-0.8611	Letonia	-0.2372	Lituania	-0.1948
Luxemburgo	0.2779	Malta	0.3125	Moldavia	-0.5913
Mónaco	0.4917	Montenegro	-0.1805	Noruega	0.4729
Países Bajos	0.3976	Polonia	-0.0121	Portugal	0.1415
Reino Unido	0.3250	Rep. Checa	-0.0089	Macedonia	-0.5577
Rumania	-0.3609	Rusia	-0.6409	Serbia	-0.5065
Suecia	0.5355	Suiza	0.5949	Turquía	0.0359
Ucrania	-0.5599				

Cuadro 4.8: Efectos aleatorios u_i estimados para cada país.

4.7.4 Interpretación del modelo ajustado

En definitiva, el modelo binomial negativo ajustado para las muertes por enfermedades del sistema nervioso es:

$$\ln(\mu_{ij}) = \ln(N_{ij}) - 3,678163 + 0,002147x_{ij} + 1,268723t_j^2 - 0,696646t_j^3 + u_i,$$

es decir,

$$\begin{aligned}\mu_{ij} &= N_{ij} \exp\left(-3,678163 + 0,002147x_{ij} + 1,268723t_j^2 - 0,696646t_j^3 + u_i\right) \\ &= N_{ij} \cdot e^{-3,678163} \cdot e^{0,002147x_{ij}} \cdot e^{1,268723t_j^2} \cdot e^{-0,696646t_j^3} \cdot e^{u_i} \\ &= N_{ij} \cdot 0,025269 \cdot 1,002150^{x_{ij}} \cdot 3,556309t_j^2 \cdot 0,498254t_j^3 \cdot e^{u_i},\end{aligned}$$

donde $u_i \sim N(0, 0,4029578)$ representa el efecto aleatorio asociado al país.

De esta forma, el producto

$$0,025269 \cdot 1,002150^{x_{ij}} \cdot 3,556309t_j^2 \cdot 0,498254t_j^3$$

4. CONTEO DE MUERTES EN EUROPA

representa la proporción estimada de defunciones por enfermedades del sistema nervioso para un país con determinado IDH en un año específico. El término $1,002150^{x_{ij}}$ muestra cómo influye el IDH: por ejemplo, si un país tiene un IDH máximo ($x_{ij} = 100$), el factor sería aproximadamente 1,2395, lo cual representa un aumento del 23,95 % en el número de defunciones por esta causa.

Esta proporción se multiplica por el número total de muertes N_{ij} para obtener el conteo esperado. Finalmente, el efecto aleatorio e^{u_i} permite ajustar la estimación según las desviaciones particulares de cada país respecto a la tendencia global. Esto resulta especialmente útil para capturar variabilidad estructural no explicada por las covariables incluidas en el modelo. Por ejemplo, dos países con el mismo IDH en el mismo año podrían presentar niveles diferentes de mortalidad debido a factores no observados (como políticas sanitarias, infraestructuras o hábitos de vida).

Veamos ahora cómo varía este factor de ajuste (e^{u_i}) entre países en el siguiente mapa de Europa:




Figura 4.27: Mapa del factor de ajuste e^{u_i} del modelo binomial negativo para enfermedades del sistema nervioso.

En el mapa, los países coloreados en azul tienen un factor menor que 1, lo que indica que presentan un número de defunciones inferior al esperado según el modelo. Por el contrario, los países en tonos rojos superan el nivel esperado. Por ejemplo, para España, se obtiene $e^{u_{41}} = e^{0,595931} = 1,814720$, lo cual implica que se esperan un 81,47 % más de fallecimientos por enfermedades del sistema nervioso en comparación con un país promedio.

4.7.5 Análisis de residuales

Para evaluar la calidad del ajuste del modelo, analizamos los residuales de Pearson, definidos como:

$$r_{P,ij} = \frac{y_{ij} - \hat{\mu}_{ij}}{\sqrt{\hat{\mu}_{ij} + a\hat{\mu}_{ij}^2}},$$

donde:

- y_{ij} es el número observado de muertes en el país i y año j ,
- $\hat{\mu}_{ij}$ es el valor estimado de muertes,
- a es el parámetro de sobredispersión estimado, es decir, α .

Cuanto más cercano a cero es un residual, mejor es el ajuste para esa observación. A continuación, mostramos cómo se distribuyen los residuales en función de distintas covariables del modelo.




Figura 4.28: Distribución de los residuales de Pearson por año.

En la Figura 4.28 se observa que el ajuste es mejor alrededor del año 2000, donde las cajas son más estrechas y la mediana se aproxima a 0. A medida que nos alejamos hacia los extremos del marco temporal, aumenta la variabilidad, lo que indica un ajuste menos preciso en esos periodos.

4. CONTEO DE MUERTES EN EUROPA




Figura 4.29: Distribución de los residuales de Pearson por IDH.

La Figura 4.29 muestra que, conforme aumenta el IDH, el modelo se ajusta mejor. Este comportamiento es coherente con la elevada correlación entre el IDH y la tasa de muertes por enfermedades del sistema nervioso.




Figura 4.30: Distribución de los residuales de Pearson por país.

Por último, en la Figura 4.30 se evidencian diferencias entre países. En algunos como

Azerbaiyán, Montenegro o Portugal, el modelo no se ajusta adecuadamente; mientras que en otros como Bulgaria, Finlandia o Francia, se observa un mejor ajuste. Como cada caja resume los datos de un mismo país a lo largo del tiempo, estas diferencias pueden deberse, en parte, a la suposición de un parámetro de sobredispersión constante en todos los países, lo cual podría no reflejar adecuadamente la heterogeneidad estructural de cada nación.

El modelo binomial negativo ajustado para las enfermedades del sistema nervioso ha demostrado ser una herramienta adecuada para modelar datos de conteo con sobredispersión. La incorporación de efectos aleatorios por país ha permitido capturar diferencias no observadas entre regiones, mejorando la interpretación y robustez del ajuste.

El IDH, inicialmente parecía relevante, y efectivamente resultó significativo en el modelo final, observado patrones importantes en la variabilidad de los residuos según su valor.

La estructura temporal capturada mediante términos cuadráticos y cúbicos del tiempo indica una evolución no lineal del fenómeno, compatible con transiciones epidemiológicas asociadas al desarrollo socioeconómico. El análisis de residuos confirma un buen ajuste global, aunque con ciertas limitaciones en los extremos temporales y en algunos países concretos.

En conjunto, este modelo proporciona una base sólida para interpretar tendencias de mortalidad por causas neurológicas y, en futuras extensiones, podría integrarse dentro de modelos más amplios o multivariantes para explorar patrones compartidos con otras causas de muerte.

CONCLUSIONES

El análisis del número de muertes y/o de la tasa de mortalidad por país en Europa plantea un problema estadístico complejo, al tratarse de datos de conteo con estructura composicional y fuerte heterogeneidad entre unidades geográficas y temporales. Para su análisis, hemos empleado modelos lineales generalizados mixtos con distribución binomial negativa, incorporando efectos aleatorios por país. Este enfoque permite tener en cuenta tanto la sobredispersión presente en los datos como parte de la variabilidad estructural entre países.

El desarrollo del trabajo ha implicado abordar cuestiones metodológicas que no forman parte del currículo habitual del grado en Matemáticas, como el ajuste de modelos para datos composicionales, el uso de regresiones de binomial negativa y su integración en un marco mixto. También se han llevado a cabo tareas de recopilación y análisis de datos para describir la evolución de la mortalidad en Europa según las categorías de causas de muerte establecidas por la OMS.

El modelo propuesto se ha apoyado en trabajos recientes, como el de Zhang et al. (*BMC Bioinformatics*), originalmente aplicado a datos de microbioma. La adaptación de esta metodología a un contexto epidemiológico ha requerido revisar bibliografía especializada y realizar ajustes a problemas no tratados de forma explícita en la literatura.

Aunque el modelo ajusta razonablemente bien y mejora respecto a enfoques más simples, los resultados indican que la inclusión de un efecto aleatorio únicamente en el intercepto no reduce de forma homogénea la variabilidad de los residuos. Como línea de trabajo futura, se propone considerar una estructura de varianza heterocedástica, permitiendo que el parámetro de sobredispersión α dependa de alguna covariable. Esto conduciría al desarrollo de un modelo generalizado para media y varianza, con mayor capacidad para reflejar la heterogeneidad en la mortalidad entre países y periodos.



APÉNDICES

A.1 Análisis de componentes principales

A.1.1 ACP 1990




Figura A.1: Matriz de correlaciones (1990)




Figura A.2: Porcentajes de variación (1990)




Figura A.3: Círculo de correlaciones (1990)




Figura A.4: Contribuciones al plano principal (1990)




Figura A.5: Calidad de representación en el plano principal (1990)

A.1. Análisis de componentes principales




Figura A.6: Representación países (1990)

A.1.2 ACP 2019




Figura A.7: Matriz de correlaciones (2019)




Figura A.8: Porcentajes de variación (2019)




Figura A.9: Círculo de correlaciones (2019)




Figura A.10: Contribuciones al plano principal (2019)




Figura A.11: Calidad de representación en el plano principal (2019)




Figura A.12: Representación países (2019)

A.2 Análisis en coordenadas principales

Vamos a realizar también un análisis en coordenadas principales (o escalamiento multidimensional). Este análisis se hará, de nuevo, en los tres conjuntos de datos que hemos construido en el ACP. Por su naturaleza composicional, no podemos utilizar las distancias Euclídea o de Manhattan. En su lugar, utilizaremos la distancia de Aitchison, que es la distancia Euclídea entre dos muestras después de aplicar la transformación CLR. Cuando representemos los puntos, de nuevo los colorearemos según su nivel de IDH.

EMD medianas temporales

Después de aplicar el escalamiento multidimensional para dos coordenadas principales obtenemos el siguiente gráfico.




Figura A.13: Representación países (medianas temporales)

Podemos apreciar que el idh es inversamente proporcional a la segunda dimensión, ya que, de forma general, cuanto más IDH tiene un país, más abajo está.

Por último, para evaluar la calidad de la representación, calcularemos los coeficientes de precisión a partir de los valores propios de la matriz de productos cruzados:

$$m_{1,2} = 93,9359641$$

$$m_{2,2} = 99,8527199,$$

con lo que vemos que hay una buena representación.

EMD 1990




Figura A.14: Representación países (1990)

$$m_{1,2} = 93,7088819$$

$$m_{2,2} = 99,8577879,$$

EMD 2019




Figura A.15: Representación países (2019)

$$m_{1,2} = 95,0677722$$

$$m_{2,2} = 99,9130634,$$

BIBLIOGRAFÍA

- [1] D. Wackerly, D. Wackerly, W. Mendenhall, and R. Scheaffer, *Estadística Matemática Con Aplicaciones*. CENGAGE Learning, 2009. [Online]. Available: [https://www.cimat.mx/ciencia_para_jovenes/bachillerato/libros/\[Wackerly,Mendenhall,Scheaffer\]Estadistica_Matematica_con_Aplicaciones.pdf](https://www.cimat.mx/ciencia_para_jovenes/bachillerato/libros/[Wackerly,Mendenhall,Scheaffer]Estadistica_Matematica_con_Aplicaciones.pdf) 2.1
- [2] R. W. M. Wedderburn, “On the existence and uniqueness of the maximum likelihood estimates for certain generalized linear models,” *Biometrika*, vol. 63, no. 1, pp. 27–32, 1976. [Online]. Available: <http://www.jstor.org/stable/2335080> 2.5
- [3] A. J. Dobson and A. G. Barnett, *An Introduction to Generalized Linear Models*, 3rd ed. Chapman and Hall/CRC, May 2008. [Online]. Available: <http://www.worldcat.org/isbn/1584889500> 2.5
- [4] E. Lehmann and G. Casella, *Theory of Point Estimation*, 2nd ed. Springer New York, NY, 1998. 2.5
- [5] X. Zhang and N. Yi, “Nbzymm: negative binomial and zero-inflated mixed models, with application to microbiome/metagenomics data analysis,” *BMC Bioinformatics*, vol. 1, no. 488, 2020. [Online]. Available: <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/s12859-020-03803-z> 3, 4.3, 4.7.3
- [6] E. Artin, *The gamma function*. Courier Dover Publications, 2015. 3.2, 3.2
- [7] G. Verbeke, G. Molenberghs, and D. Rizopoulos, *Random Effects Models for Longitudinal Data*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, pp. 37–96. 3
- [8] D. Bates, M. Mächler, B. Bolker, and S. Walker, “Fitting linear mixed-effects models using lme4,” *Journal of Statistical Software*, vol. 67, no. 1, p. 1–48, 2015. [Online]. Available: <https://www.jstatsoft.org/index.php/jss/article/view/v067i01> 3.4.3
- [9] J. J. Doblas Martínez, “GitHub repository: TFG,” <https://github.com/juanjodoblasm/TFG>, 2025. 4.1
- [10] S. Lubbe, P. Filzmoser, and M. Templ, “Comparison of zero replacement strategies for compositional data with large numbers of zeros,” *Chemometrics and Intelligent Laboratory Systems*, vol. 210, p. 104248, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0169743921000162> 4.3, 4.3.1

- [11] J. Aitchison, C. Barceló-Vidal, J. A. Martín-Fernández, and V. Pawlowsky-Glahn, “Logratio analysis and compositional distance,” *Mathematical geology*, vol. 32, pp. 271–275, 2000. 4.3.2